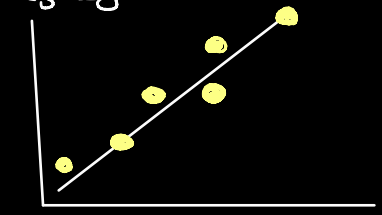
V. Bölüm – Least Squares, Regresyon Loss

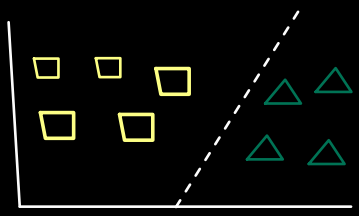
Regresyon ve Sınıflandırma nedir?

* Makine öğrenmesindeki temel problemlerden ikisi regresyon ve sınıflandırmadır.

Regresyon



Sınıflandırma



Özellik	Regresyon	Sınıflandırma
Hedef	Sayısal değer	Kategori
Örn:	Ev fiyatı 2300 TL	Ev hasarı
Çıktı	65.4	Hasarsız
	Lineer Regresyon	Lojistik Regresyon

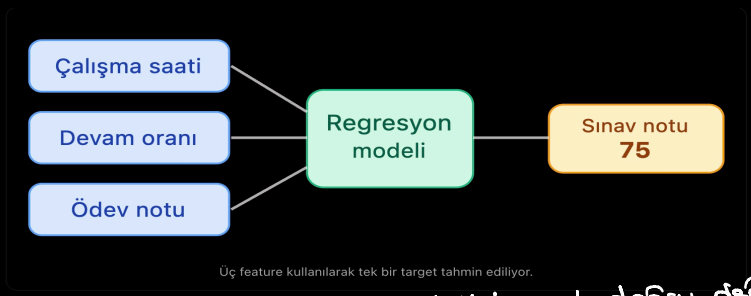
Feature ve Target

* Feature (öz nitelik), modelin tahmin yaparken kullandığı girdidir. Target (hedef), tahmin etmek istediği

* matematiksel olarak:

$$X = \begin{bmatrix} x_{11} & x_{12} & x_{13} \dots & x_{1n} \\ x_{21} & x_{22} & x_{23} \dots & x_{2n} \\ \vdots & & & \\ x_{n1} & x_{n2} & \dots & x_{nn} \end{bmatrix}, \quad y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

Burda X girdileri, y ise gerçek hedef değerini içerir.



Üç feature kullanılarak tek bir target tahmin ediliyor.

Dikkat

– Bir feature, tahmin yapılacağı anda elde edilebilir olmalıdır. Sınav notunu tahmin ederken sınav bittikten sonra oluşan bilgiyi kullanmak doğru değildir.

Basit Doğrusal Regresyon

$$\hat{y} = \beta_0 + \beta_1 \cdot x$$

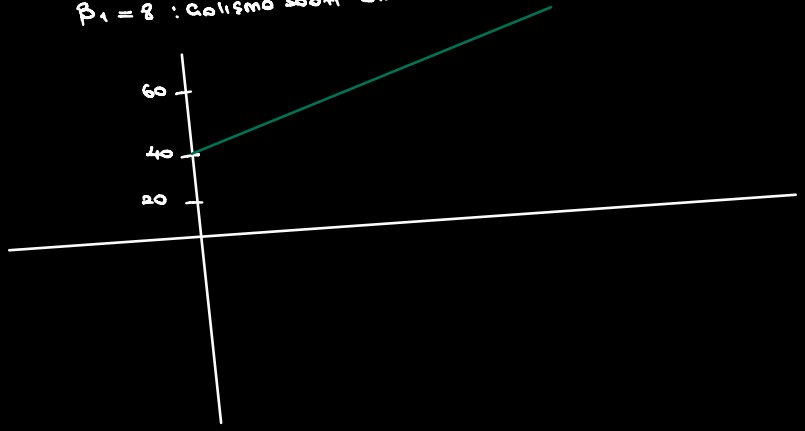
Sembollerin anlamı;

- x = Girdi
- β_1 = Slope (eğim)
- β_0 = Sabit terim
- $\hat{y}$ = Gerçek değer

Örnek: $y = 40 + 8x$

$\beta_0 = 40$: Çalışma saati 0 iken modelin tahmini 40 puandır.

$\beta_1 = 8$: Çalışma saati birim artığında tahmin 8 artar



Residual (Artık (hata) Kavramı)

* Bir modelin tahmin ettiği gerçek değerden farklı olabilir. Aralarındaki fark residual olarak adlandırılır.

$$e_i = y_i - \hat{y}_i$$

- $e_i > 0$ ise gerçek değerden düşük tahmin etmiş.
- $e_i < 0$ ise model değerden yüksek tahmin etmiş.
- $e_i = 0$ ise tahmin doğrudur.

Örnek:

Çalışma Süresi	Gerçek Not
1	45
2	50
3	62
4	68
5	80

Yukarıda verilen çalışma süresi ile eğitilmiş modelin formülü:

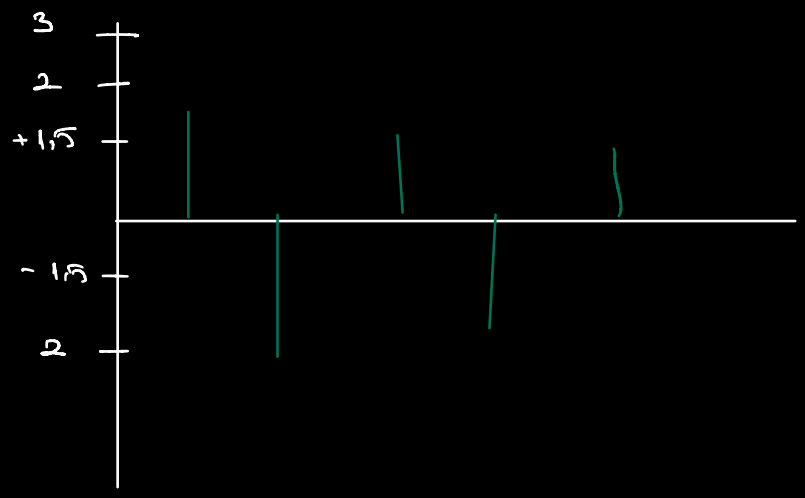
$$y = 34{,}6 + 8{,}8x$$

ile verilmiştir. Buna göre tahminlerin hatalarını ve residual grafiğini çiziniz.

Çözüm:

x	y	$\hat{y}$	$y - \hat{y}$
1	45	43,4	+1,6
2	50	52,2	-2,2
3	62	61	+1
4	68	68,8	-1,8
5	80	78,6	+1,4

Residual Grafiği:



Hata Ölçüleri – MAE, MSE ve RMSE

1. MAE – Mean Absolute Error

* Ortalama mutlak hata:

$$MAE = \frac{1}{n} \sum |y_i - \hat{y}_i|$$

Örnek: $e = [5, -5, 3, -3]$

$$MAE = \frac{+5+5+3+(+3)}{4} = 4$$

2. MSE – Mean Squred Error

* Ortalama karesel hata:

$$MSE = \frac{1}{n} \sum (y_i - \hat{y}_i)^2$$

Örnek: $MSE = \frac{5^2+5^2+3^2+3^2}{4} = 17$

3. RMSE – Root Mean Squred Error

* Kök ortalama karesel hata:

$$RMSE = \sqrt{MSE}$$

Outlier Neden "önemlidir"?

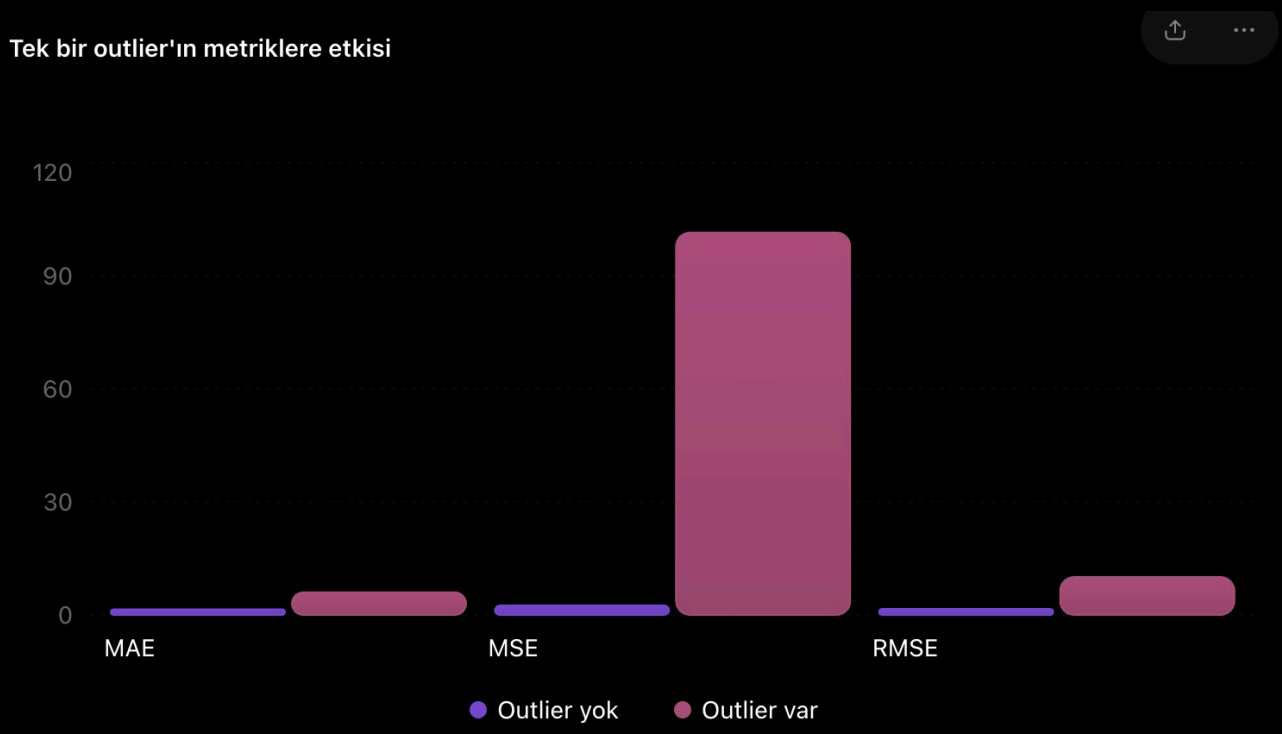
* İlk residual kümesi:

$e = [1, -2, 1, 2]$

– Bir uç değer eklendiğinde

$e' = [1, -2, 1, 20]$

Metrik	Normal	Outlier eklenmiş	Artış
MAE	1,5	6	4 kat artış
MSE	2,5	101,50	x 40,6 artış
RMSE	1,58	10,07	x 6,4 kat



Bu yüzden metriği problemimize göre seçmeliyiz. Büyük tahmin hatalarının ciddi maliyetleri varsa MSE veya RMSE uygun olabilir. Ölçüm hatalarına karşı daha az hassas bir değerlendirme isteniyorsa MAE yararlı olabilir.

Sınav sorusu: MSE neden MAE'den daha fazla outlier etkisi altında kalır?

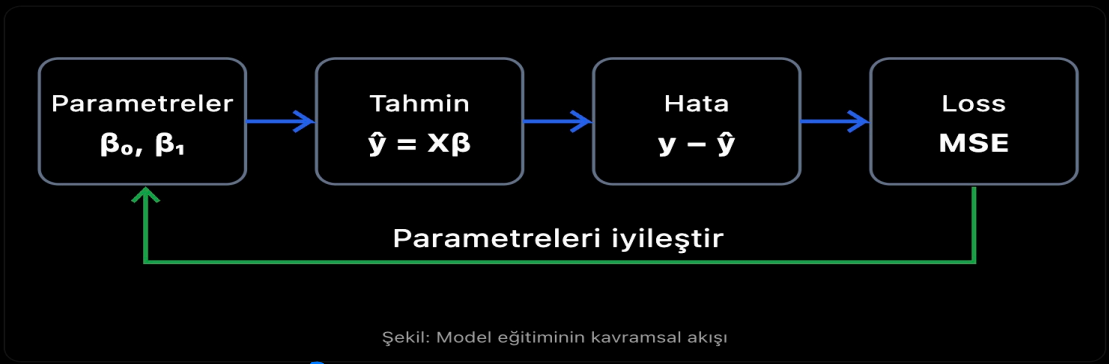
Cevap: Çünkü MSE residual'ın karesini alır. Hata 10 katına çıktığında kare hata cezası 100 katına çıkar. MAE ise aynı durumda yalnızca 10 kat artar.

Loss Fuction (Kayıp Fonksiyonu)

* Loss fuction, modelin yaptığı hatayı sayısal olarak ifade eden ve eğitimi sırasında küçülmeye çalışan fonksiyondur.
* "Örneğin doğrusal regresyon için MSE loss":

$$L(\beta_0, \beta_1) = \frac{1}{n} \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 \cdot x_i)^2$$

Bu fonksiyonun girdileri modelin parametreleridir. Bu parametreler değiştikçe tahminler, dolayısıyla loss değişir.



Şekil: Model eğitiminin kavramsal akışı

Loss ile evaluation metric farkı

— Loss, modelin eğitiminde kullanılan optimizasyon hedefidir. Metric ise eğitim tamamlandıktan sonra performansı değerlendirmeye yarar

"Örnek:

- Modelin MSE minimize ederek eğitiriz.
- Test performansını MAE, RMSE ve R^2 ile raporlarız.

Bunun nedeni her zaman aynı metriğin eğitim ve raporlama için en uygun seçenek olmasıdır.

Least Squares - En Küçük Kareler Yöntemi

* Least squares, residual kareleri toplamını en küçük yapan model parametrelerini kullanır.

$$\min_{\beta_0, \beta_1} \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2$$

Burdaki min, hangi parametrenin hataların toplamını en aza indirdiğini anlamına gelir

Örnek:

Çalışma Süresi	Gerçek Not
1	45
2	50
3	62
4	68
5	80

$$m = \frac{n \cdot \sum x_i y_i - \sum x_i \cdot \sum y_i}{n \sum x_i^2 - (\sum x_i)^2} \qquad n = \frac{\sum y_i - m \cdot \sum x_i}{n}$$

bu formüller kullanılacak fonksiyon $y = 34.6 + 8.8x$

modelin tahmini = 1.6, -2.2, 1, -1.8, 1.4

$SSE = 1.6^2 + (-2.2)^2 + 1^2 + (-1.8)^2 + 1.4^2$

$= 13.6$

$MSE = \frac{13.6}{5} = 2.72$

Design Matris - Regresyon matris Gösterimi

* Elimizde üç gözlem var:

$$x = [1, 2, 3]$$

* Regresyon denklemi yazılırsa:

$$\hat{y}_1 = \beta_0 + \beta_1(1)$$
$$\hat{y}_2 = \beta_0 + \beta_1(2)$$
$$\hat{y}_3 = \beta_0 + \beta_1(3)$$

Bunları tek matris çarpımına dönüşürse

$$\begin{bmatrix} \hat{y}_1 \\ \hat{y}_2 \\ \hat{y}_3 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix} \cdot \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix} \quad \text{kısaca} \rightarrow \quad \hat{y} = X \cdot \beta$$

($\hat{y}$, X, β)

* İlk sütun neden 1?
– Çünkü sabit terimi matris çarpımına katmamız gerekir.

Design Matris Boyutu

– n gözlem d feature için

$$X \in R^{n \times (d+1)}$$

Örneğin; 100 gözlem 3 feature;

$$X.shape = (100, 4)$$

Least Squares Problemi'nin matris biçimi

* Bütün tahminler:

$$\hat{y} = X \cdot \beta$$

* Residual vektörü:

$$r = y - X\beta$$

* Residual kareleri toplamı:

$$\|r^2\| = r^T \cdot r$$

* Böylece Least Squares hedefi şu şekilde

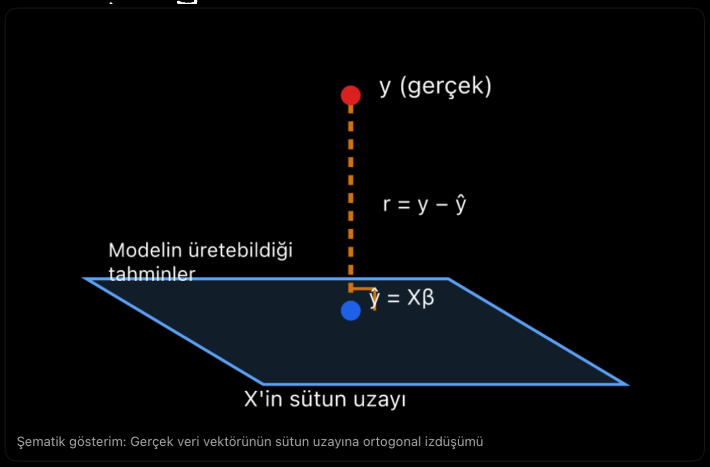
$$\min_{\beta} \|y - X\beta\|_2^2$$

* Bu gösterimi; veriler x ve y sabittir. β'yı değiştirmek gerçek değerler arasında tahminler arasındaki Öklid uzaklığının karesini minimum yapılması isteniz.

Not: Burda $\| \ \|_2$ öklid normu, $\| \ \|_2$ öklid normunun karesini ifade eder.

Geometrik Yorum: Least Squares bir izdüşümdür.

* Her $X\beta$ vektörü, X'in sutunlarının doğrusal biçimidir. Bu sütunların oluşturduğu uzaya column space (sütun uzayı) denir.
* Gerçek y vektörü bu uzayın dışında kalabilir. Model her gerçek değeri kusursuz edemeyebilir.



Şematik gösterim: Gerçek veri vektörünün sütun uzayına ortogonal izdüşümü

En yakın noktayı bulduğumuzda residual vektörü 'r', sütun uzayına diktir.

Normal Equation - Normal Denklem

* En küçük kareler çözümün şu şekilde geometrik türetilir:

- Residual:

$$r = y - X\beta$$

- En iyi çözümde sutunlar diktir:

$$X^T \cdot r = 0$$

- Yerine koyulursa:

$$X^T (y - X\beta) = 0$$

- Carpim dağitilirsa:

$$X^T \cdot y - X^T \cdot X \cdot \beta$$

- son halde

$$\boxed{X^T \cdot X \cdot \beta = X^T \cdot y}$$ → Bu ifadeye Normal Equals denir.

Örn: $X = [1,2,3]$ $y = [2,4,5]$

Bu ifadeyi β_0 ve β_1 değerlerini bulunuz.

Design matris:

$$X = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix} \qquad X^T = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{bmatrix}$$

$X^T \cdot X$ hesapla;

$$\begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{bmatrix} \cdot \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix} = \begin{bmatrix} 1.1+1.1+1.1 & 1.1+1.2+1.3 \\ 1.1+2.1+3.1 & 1.1+2.2+3.3 \end{bmatrix} = \begin{bmatrix} 3 & 6 \\ 6 & 14 \end{bmatrix}$$

$X^T \cdot y$ hesapla:

$$\begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{bmatrix} \begin{bmatrix} 2 \\ 4 \\ 5 \end{bmatrix} = \begin{bmatrix} 2.1+4.1+5.1 \\ 1.2+4.2+5.3 \end{bmatrix} = \begin{bmatrix} 11 \\ 25 \end{bmatrix}$$

Denklem

$$\begin{bmatrix} 3 & 6 \\ 6 & 14 \end{bmatrix} \cdot \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix} = \begin{bmatrix} 11 \\ 25 \end{bmatrix}$$

$$-2/\ 3\beta_0 + 6\beta_1 = 11$$
$$+\quad 6\beta_0 + 14\beta_1 = 25$$

$$2\beta_1 = 3$$
$$\beta_1 = 3/2 = 1.5$$

$$3.\beta_0 + 6.1.5 = 11$$
$$3\beta_0 = 2$$
$$\beta_0 = \frac{2}{3}$$

Numpy'le Least Squares uygulaması

*Veri:

$x = [1,2,3,4]$ $y = [2,3,5,6]$

11.1 Design matrix oluşturma

```python
import numpy as np

x = np.array([1., 2., 3., 4.])
y = np.array([2., 3., 5., 6.])

X = np.column_stack([
    np.ones(len(x)),
    x
])

print(X)
print("Boyut:", X.shape)
```

Çıktı:

```
[[1. 1.]
 [1. 2.]
 [1. 3.]
 [1. 4.]]

Boyut: (4, 2)
```

`np.ones()` birler sütununu üretir. `np.column_stack()` ise sütunları birleştirerek tasarım matrisini oluşturur.

11.2 Parametreleri öğrenme

```python
beta, residuals, rank, s = np.linalg.lstsq(
    X, y, rcond=None
)

print("Parametreler:", beta)
print("SSE:", residuals)
print("Rank:", rank)
print("Singular values:", s)
```

Beklenen çıktı:

```
Parametreler: [0.5 1.4]
SSE: [0.2]
Rank: 2
Singular values: [5.7794 0.7738]
```

Dönen değerlerin anlamları:

Değer	Açıklama
`beta`	Bulunan regresyon parametreleri
`residuals`	Uygun koşullarda residual kareleri toplamı (SSE)
`rank`	Design matrix'in rank değeri
`s`	Singular values (tekil değerler)

Dolayısıyla:

$$\boxed{\hat{y} = 0{,}5 + 1{,}4x}$$

11.3 Tahminleri ve metrikleri hesaplama

```python
y_hat = X @ beta
e = y - y_hat

mae = np.mean(np.abs(e))
mse = np.mean(e ** 2)
rmse = np.sqrt(mse)
sse = np.sum(e ** 2)

print("Tahminler:", y_hat)
print("Residual:", e)
print("MAE:", mae)
print("MSE:", mse)
print("RMSE:", rmse)
print("SSE:", sse)
print("Diklik kontrolü:", X.T @ e)
```

Sonuçlar:

x	Gerçek y	Tahmin ŷ	Residual
1	2	1,9	+0,1
2	3	3,3	−0,3
3	5	4,7	+0,3
4	6	6,1	−0,1

$$MAE = 0{,}2$$

$$MSE = 0{,}05$$

$$RMSE \approx 0{,}2236$$

$$SSE = 0{,}2$$

11.4 Regresyon grafiğini çizme

```python
import numpy as np
import matplotlib.pyplot as plt

x = np.array([1., 2., 3., 4.])
y = np.array([2., 3., 5., 6.])

X = np.column_stack([np.ones(len(x)), x])
beta = np.linalg.lstsq(X, y, rcond=None)[0]

y_hat = X @ beta

plt.figure(figsize=(8, 5))
plt.scatter(x, y, label="Gerçek veriler", s=75)
plt.plot(x, y_hat, label="Regresyon doğrusu")

for xi, yi, pred in zip(x, y, y_hat):
    plt.plot([xi, xi], [yi, pred], color="gray",
             linestyle="--")

plt.xlabel("X")
plt.ylabel("Y")
plt.title("Least Squares — Doğrusal Regresyon")
plt.grid(alpha=0.25)
plt.legend()
plt.show()
```

Bu grafikte noktalar gerçek değerlerdir, çizgi öğrenilen regresyon doğrusudur. Kesikli dikey çizgiler residual'ları gösterir.

12. scikit-learn ile doğrusal regresyon

NumPy ile yaptığımız işlemleri scikit-learn kütüphanesiyle daha kısa yazabiliriz.

```python
import numpy as np
from sklearn.linear_model import LinearRegression

x = np.array([1., 2., 3., 4.])
y = np.array([2., 3., 5., 6.])

model = LinearRegression()
model.fit(x.reshape(-1, 1), y)

print("Intercept:", model.intercept_)
print("Eğim:", model.coef_)
print("R2:", model.score(x.reshape(-1, 1), y))
```

Çıktı:

```
Intercept: 0.5
Eğim: [1.4]
R2: 0.98
```

12.1 `reshape(-1, 1)` neden gerekli?

NumPy'da:

```python
x.shape
# (4,)
```

Ama scikit-learn feature matrisini iki boyutlu bekler:

```python
x.reshape(-1, 1).shape
# (4, 1)
```

Bunun anlamı: 4 gözlem, 1 feature.

R^2 - Determinasyon Katsayısı

* MAE ve MSE hatanın ne kadar olduğunu gösterir. Fakat modelin basit bir tahmin stratejisinden başarılı olup olmadığını bilemeyiz. Bunun için baseline kullanılır.

Baseline Nedir?

- Regresyonda basit bir başlangıç modeli, hedef değerlerin eğitim ortalamasını tahmin eder.

Öğrenci verisi = $y = [45, 50, 62, 68, 80]$

Ortalama = $\frac{45+50+62+68+80}{5} = 61$ → Baseline herkesi 61 tahmin eder.

SST ve SSE

* SST, gerçek değerlerin ortalamadan karesel sapmasıdır.

$$SST = \sum_{i=1}^{n} (y_i - \hat{y})^2$$

* SSE ile regresyon modelinin hata kareleri toplamıdır.

$$SSE = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$

* R^2 formülü =

$$R^2 = 1 - \frac{SSE}{SST}$$

Örnek: SST = 788 SSE = 13,6 ise R^2 = ?

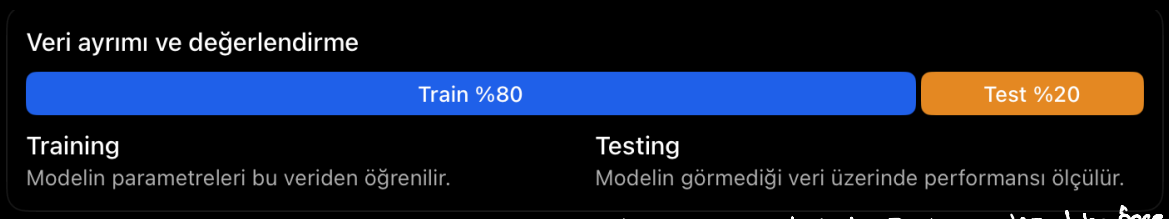
$$R^2 = 1 - \frac{13,6}{788} \cong 0,8827$$

R^2 yorumlanması

R^2	anlam
1	Kusursuz uyum
0,8	Baseline'a göre çok uyumlu hata 0'a olması
0,5	Baseline kare hatası yarıya indi
0	Basline aynı kare hata
$R^2 < 0$	Daha kötü

Train ve Test Error

* Makine öğrenmesinde verin tamamıyla model eğitip sonra aynı veri üzerinde performans ölçmek yanıltıcı olabilir.



* Training error, modelin eğitimde kullandığı veri üzerindeki hatadır. Test error ise daha önce görmediği verideki hatasıdır.

* Test hatası daha yüksek olabilir ancak her zaman geçerli değildir.

14.1 Overfitting (Aşırı öğrenme)

Model eğitim verisinin genel eğilimini öğrenmek yerine o veriye özgü gürültüyü de öğrenebilir.

Bu durumda:

- Training error çok düşüktür.
- Test error belirgin şekilde daha yüksek olur.
- Model yeni verilerde iyi genelleme yapamaz.

14.2 Python ile doğru train/test ayrımı

```python
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score

rng = np.random.default_rng(42)

# Örnek veri: Doğrusal ilişki + rastgele gürültü
X = rng.uniform(1, 10, size=(100, 1))
y = 30 + 7 * X[:, 0] + rng.normal(0, 5, size=100)

X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42
)

model = LinearRegression()
model.fit(X_train, y_train)

train_pred = model.predict(X_train)
test_pred = model.predict(X_test)

print("Train MAE:", mean_absolute_error(y_train, train_pred))
print("Test MAE:", mean_absolute_error(y_test, test_pred))
print("Test MSE:", mean_squared_error(y_test, test_pred))
print("Test RMSE:", np.sqrt(mean_squared_error(y_test, test_pred)))
print("Test R2:", r2_score(y_test, test_pred))
```

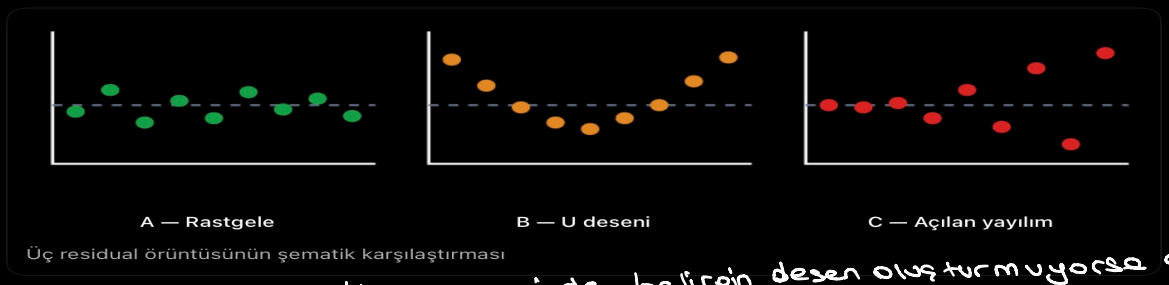
Kodun önemli noktası:

```python
model.fit(X_train, y_train)
```

Test verisi üzerinde `fit()` çağrılmaz. Test performansı `predict()` ile oluşturulan tahminler üzerinden hesaplanır.

Residual Plot - Modelin uygunluğunu kontrol etmek

*Bir residual grafiği genellikle yatay eksene tahminler ve feature, dikey eksene residual yerleştirilir.



Üç residual örüntüsünün şematik karşılaştırması

A - Rasgele dağılım = Residual'lar çevresinde belirgin desen oluşturmuyorsa doğrusal model kabul edilir.

B - U deseni: Doğrusal modelin açıklayamadığı eğrisel ilişki olabilir.

C - Açılsal desen: Hatanın yayılımı tahmin değerini artırıyor ve azaltıyor olabilir.

Python kodu

```python
import matplotlib.pyplot as plt

residual = y_test - test_pred

plt.figure(figsize=(8, 5))
plt.scatter(test_pred, residual)
plt.axhline(0, color="red", linestyle="--")

plt.xlabel("Tahmin edilen değer")
plt.ylabel("Residual")
plt.title("Residual Plot")
plt.grid(alpha=0.25)
plt.show()
```

İyi bir R^2 görmek yeterli değildir. Residual grafiği modelin sistematik olarak nerelerde hata yaptığını gösterebilir.

16. Outlier ve regresyon doğrusuna etkisi

Outlier sadece MAE ve MSE'yi artırmaz; öğrenilen regresyon doğrusunu da değiştirebilir.

Ders materyalinin 26. sayfasındaki deneyde tek uç gözlem eklendiğinde:

Ölçü	Outlier yok	Outlier var
Eğim	7,84	2,43
R^2	0,997	0,095

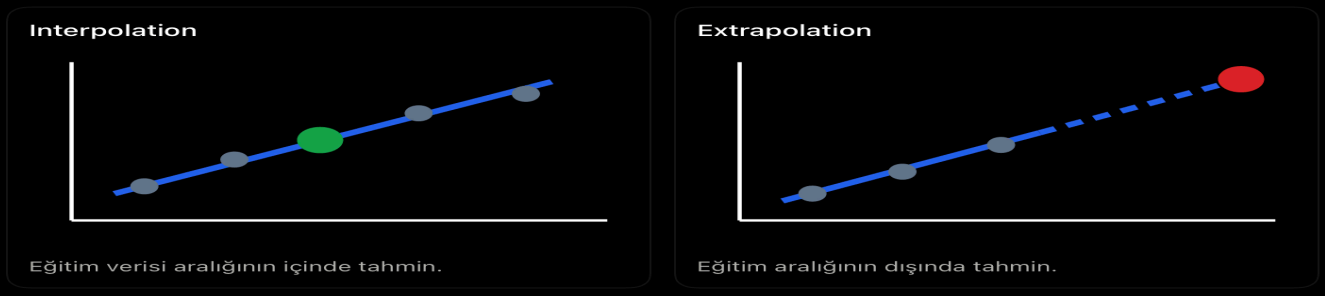
Bu değişim oldukça büyüktür.

Bunun nedeni Least Squares yönteminin büyük residual karelerini azaltmaya çalışmasıdır. Tek uç gözlemin karesi çok yüksek olduğu için regresyon doğrusunu kendi yönüne çekebilir.

Uç değer görünce hemen silmeyiz. Önce bunun veri giriş hatası mı, ölçüm hatası mı, yoksa gerçekten gerçekleşmiş önemli bir olay mı olduğunu araştırırız.

17. Interpolation ve Extrapolation

Regresyon modeli eğitim verilerinin dışındaki noktalarda da tahmin üretir. Ancak her tahminin güvenilirliği aynı değildir.



Daha önceki modelimiz:

$$\hat{y} = 34{,}6 + 8{,}8x$$

Eğitim aralığımız 1–5 saat olsun.

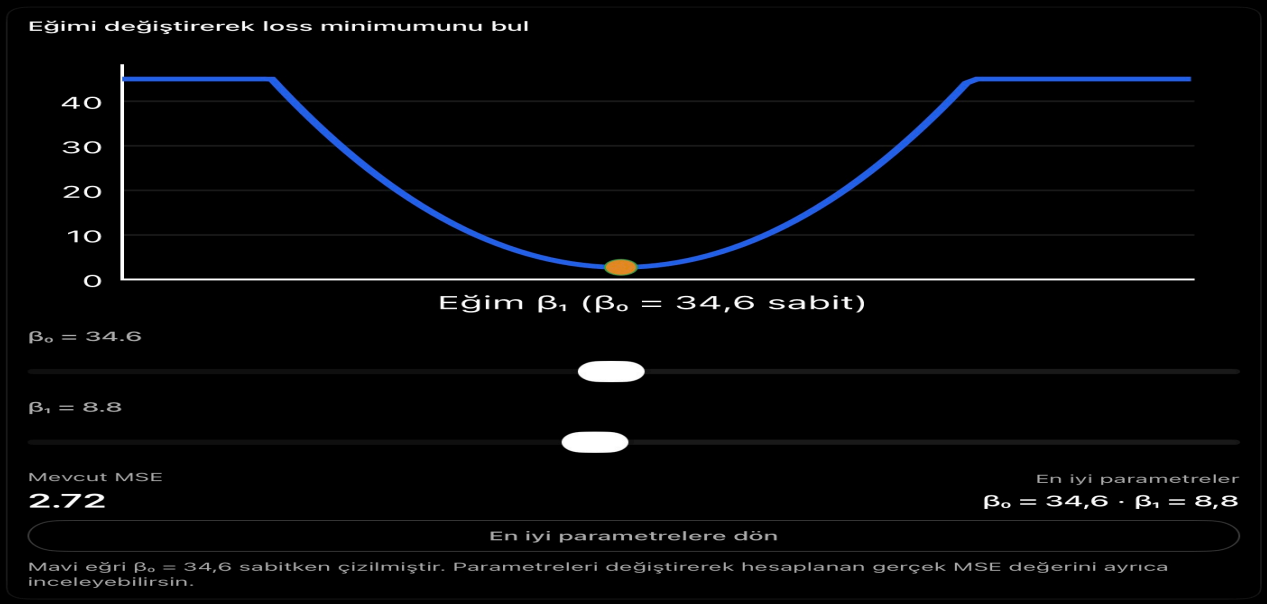
- $x = 3$ için tahmin 61 puandır. Bu interpolation'dır.
- $x = 10$ için tahmin 122,6 puandır. Bu extrapolation'dır.

18. Loss yüzeyi ve minimum noktası

Parametreleri değiştirdiğimizde loss değerinin nasıl değiştiğini düşünelim.

$$L(\beta_0, \beta_1) = \frac{1}{n}\sum(y_i - \beta_0 - \beta_1 x_i)^2$$

Dersin 28. sayfasında bu ilişki bir çanak yüzeyi olarak gösterilir.



Squared error fonksiyonu, doğrusal regresyon parametrelerine göre konveks bir ikinci dereceden fonksiyondur. Tam sütun rank koşulunda tek bir minimum noktası vardır. Bu nedenle Least Squares için normal denklem gibi doğrudan çözüm yöntemleri kullanılabilir.