I. Bölüm - Vektörler ve Veri Temsili

Veri Temsili Nedir?

* Bilgisayarlar insan, ev, görüntü, metin veya sensör kaydı gibi gerçek dünya nesnelerini doğrudan anlayamaz. Bu nedenle gerçek dünyadaki nesneleri sayısal biçimde temsil edilmesi gerekir.

* Genel Süreç:

Gerçek Dünyadaki nesne → Özellikler → Sayılar → Vektör → Uzaklık / Benzerlik → Veri Bilimi Kararı

Örneğin; bir öğrenciyi bilgisayarda temsil etmek:

- yaş = 22
- boy = 175 cm
- Ortalama çalışma süresi = 3

- Bu öğrenci bilgisayarda:

$$x = [22, 175, 3]$$

şeklinde temsil edilir.

Skaler Kavramı

* Skaler (skalar) yalnızca tek bir sayı ile ifade edilen niceliktir.

Örnek: Yaş = 21
Sıcaklık = 13
Piksel Parlaklığı = 127
Accuracy = 0.97

Bunların her biri yalnızca bir sayı ile ifade edilir.

Vektör Nedir?

* Vektör, bir nesneyi birden fazla sayıyla ifade eden yapıdır.

* Genel gösterimi:

$$x = [x_1, x_2, \ldots\ldots, x_n]$$

Burda:
- x_1 = 1. özellik
- x_2 = 2. "
- x_n = son özellik
- d = vektör uzunluğu

Örnek: $x = [22, 175, 3]$
- 3 → son özellik
- 175 → 2. özellik
- 22 → 1. özellik

d = 3,

* Vektörlerde sıra sabittir.

Feature (Özellik)

*feature, bir gözlem hakkında ölçülen veya kullanılan özelliktir.

Örneğin bir ev için;

- alan
- oda sayısı
- bina yaşı
- merkeze uzaklık

} feature (özellik) olabilir.

- Ev:

alan = $225m^2$

oda sayısı = 6

yaş = 3

merkeze uzaklık: 5km

ise

$$x = [225, 6, 3, 5]$$

olur. Burada 4 feature (özellik) olduğundan $d = 4$

*feature seçimi önemlidir. Çünkü hangi bilgilerin modele dahil edileceğine kullanıcı karar verir.

Örneğin aynı ev:

- balkon sayısı
- kat
- bina tipi
- depreme dayanıklık

gibi featurelarda eklenebilir.

Dimension (Boyut)

*Bir vektörün dimensionu, içerdiği feature sayısıdır.

*Örneğin;

$x = [12, 120, 3]$ ⟶ dimension = 3

*Dimension ile norm aynı şey değildir.

Örneğin = $x = [3, 4]$

dimension = 2

l_2 normu = $|\sqrt{3^2+4^2}| = 5$

Veri kümesinde vektörler

* Birden fazla öğrenci olsun

$x_1 = [22, 175, 80]$

$x_2 = [21, 200, 100]$

$x_3 = [20, 178, 50]$

Bu verileri tablo halinde yazarsak:

	Yaş	Boy	Kilo
1	22	175	80
2	21	200	100
3	20	178	50

Her satır → bir gözlem (vektör)

Her sütun → bir feature

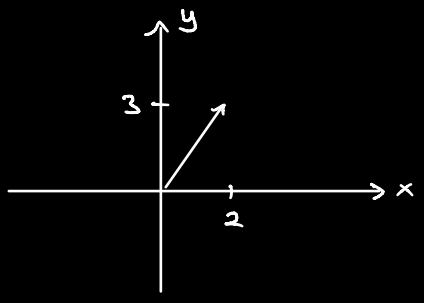
* Bu yapı tablolar yapı olarak ifade edilir.

Vektörün Geometrik Anlamı

* İki boyutlu bir vektör:

$x = [2, 3]$

Kordinat sisteminde orjinden başlayıp (3,2) noktasına giden ok gibi düşünülebilir.



Vektörün:

- uzunluğu ⇒ büyüklüğünü
- yönü ⇒ hangi tarafa baktığı

ifade eder.

Norm ve distance = uzunluğuyla ilgilenir.
Cosine simority ⇒ yönüyle ilgilenir.

Vektörlerle İşlemler

8. Temel Vektör İşlemleri

8.1. Vektör Toplama

İki vektör bileşen bileşen toplanır.

$x = [2, 1]$

$y = [1, 3]$

ise:

$x + y = [2 + 1, 1 + 3]$

$x + y = [3, 4]$

Genel olarak:

$x + y = [x_1 + y_1, x_2 + y_2, ..., x_d + y_d]$

9. Vektör Çıkarma

Yine bileşen bileşen yapılır.

$x = [2, 1]$

$y = [1, 3]$

ise:

$x - y = [2 - 1, 1 - 3]$

$x - y = [1, -2]$

Çıkarma özellikle uzaklık hesaplarında önemlidir.

Çünkü:

$d(x, y) = ||x - y||$

Yani iki nokta arasındaki uzaklık, **fark vektörünün uzunluğudur.**

10. Skalerle Çarpma

Bir vektörü skalerle çarpmak, bütün bileşenlerini aynı sayıyla çarpmaktır.

$x = [2, 1]$

ise:

$2x = [4, 2]$

$0.5x = [1, 0.5]$

$-x = [-2, -1]$

Pozitif skaler genellikle vektörün uzunluğunu değiştirirken doğrultusunu korur.

Negatif skaler ise ayrıca yönünü tersine çevirir.

Örneğin:

$x = [1, 1]$

ve

$2x = [2, 2]$

aynı yönü gösterir.

Bu özellik cosine similarity konusunda önemlidir.

Norm Nedir?

* Norm, bir vektörün büyüklüğünü ifade eder.
* Geometrik olarak vektörün orijine olan uzaklığı şeklinde düşünülebilir.
* İki önemli norm vardır:
  1. L1 norm
  2. L2 norm

1. L2 Norm – Euclidean Norm

* L2 norm pisagor teoreminin genelleştirilmiş halidir.
* formülü:

$$\|x\|_2 = \sqrt{x_1^2 + x_2^2 + x_3^2 + \dots + x_d^2}$$

Örnek: $x = [3, 4]$ vektörünün L2 normu?

$$\|x\|_2 = \sqrt{3^2 + 4^2}$$
$$= 5$$

2. L1 Norm – Manhatan Norm

* L1 norm bileşenlerin mutlak değerleri toplar.

$$\|x\|_1 = |x_1| + |x_2| + \dots + |x_d|$$

Örnek: $x = [3, 4]$ vektörünün L1 normu?

$$\|x\|_1 = |3| + |4|$$
$$= 7 //$$

Distance – İki vektör arası uzaklık

* Norm tek vektörün büyüklüğünü ölçerken distance iki vektör arası uzaklığı ölçer.
* Temel ilişki:

$$d(x, y) = |x - y|$$

Önce iki vektörün farkı bulunur, bu fark vektörünün normu hesaplanır.

1. Euclidean Distance

* Euclidean distance, iki nokta arasındaki
* formülü:

$$d_2(x, y) = \sqrt{\sum_{i=1}^{d} (x_i - y_i)^2}$$

Örneğin: $A = [1, 2]$
$B = [4, 6]$

$$B - A = [(4-1) + (6-2)]$$
$$= (3, 4)$$
$$= \sqrt{3^2 + 4^2}$$
$$= 5 //$$

2. Manathan Distance

* Manathan distance eksenler boyunca giden mesafeyi ölçer
* formül:

$$d_1(x, y) = \sum_{i=1}^{d} |x_i - y_i|$$

Örnek: $A = [1, 2]$
$B = [4, 6]$

$$d_1(A, B) = |4-1| + |6-2|$$
$$= 7 //$$

* Birden fazla distance kullanma nedenleri:

– Örneğin:

- GPS (fiziksel düz mesafe) → Euclidian
- Şehir içi, zigzag yollar → Manhattan

Feature Scaling Problemi

* Uzaklık tabanlı yöntemlerde featurelerin ölçekleri önemlidir.

Örneğin; $A = [20, 20.000]$

$B = [30, 21000]$

olsun.

Burda:

İlk feature = yaş

İkinci " = maaş

Euclian Distance $= d(A,B) = \sqrt{(30-20)^2 + (21000-20000)^2}$

$= \sqrt{10^2 + 1000^2}$

$\cong 1000.05$

* Burdaki sorun

yaş farkı = 10

Gelir farkı = 1000

olduğu için gelir feature hesabında baskın gelmiştir. Ancak sayının büyük olması feature etkileceği anlamına gelmez. Bu durumda ölçek problemi (scaling problem) ortaya çıkar.

Feature Scaling

* feature'ların karşılaştırılabilir ölçeklere getirilmesine feature scaling denir.

Min-Max Normalization

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}}$$

Sonuç genellikle:

$[0, 1]$

aralığına getirilir.

En küçük değer:

0

en büyük değer:

1

olur.

Standardization — Z-score

Formülü:

$$z = \frac{x - \mu}{\sigma}$$

Burada:

$\mu = ortalama$

$\sigma = standart\ sapma$

Standardization sonrasında feature'ın ortalaması 0, standart sapması 1 olacak şekilde ölçeklenir.

Bu haftadaki temel mesaj:

> Uzaklık tabanlı bir yöntem kullanılıyorsa feature scaling gerekip gerekmediği mutlaka düşünülmelidir.

Dot Product - İç Çarpım

* İki vektörün karşılıklı bileşenlerinin çarpılıp sonuçların toplanmasıdır.
* Formül:

$$x.y = \sum_{i=1}^{d} x_i.y_i$$

Örneğin;

$x = [1,3]$ $y=[2,4]$

$x.y = 1.2 + 3.4$

$= 14$

Dot Product Geometrik Anlamı

- Dot product aynı zamanda:

$$x.y = \|x\|_2 \|y\|_2 . \cos\alpha$$

şeklinde ifade edilir

- Aynı yöne yakınsa

$\alpha < 90$

$\cos\alpha > 0$ ise pozitif

- Dikse dot product 0'dır.
- Zıt yönlere bakıyorsa negatiftir.

Cosine Similarty

* Dot product hem büyüklükten hemde yönden etkilenir. Eğer yanlızca yön benzerliğini ölçmek için cosine similarty kullanılır.
* Formül:

$$\cos(x,y) = \frac{x.y}{\|x\|_2 . \|y\|_2}$$

Değer oralığı:

$$-1 \leq \cos(x,y) \leq 1$$

- $\cos(x,y) = 1$ ise aynı yön
- $\cos(x,y) = 0$ ise dik
- $\cos(x,y) = -1$ ise zıt yön

$x = [1, 1]$

$y = [2, 2]$

olsun.

1. Dot product

$x \cdot y = 1(2) + 1(2)$

$= 4$

2. x'in normu

$||x|| = \sqrt{1^2 + 1^2}$

$= \sqrt{2}$

3. y'nin normu

$||y|| = \sqrt{2^2 + 2^2}$

$= \sqrt{8}$

4. Cosine

$cos(x, y) = \frac{4}{\sqrt{2}\sqrt{8}}$

$= \frac{4}{\sqrt{16}}$

$= \frac{4}{4}$

$cos(x, y) = 1$

Burada:

$x \neq y$

olmasına rağmen cosine similarity 1'dir.

Çünkü:

$y = 2x$

24. Euclidean Distance ile Cosine Similarity Arasındaki Fark

Çok önemli bir örnek:

$A = [1, 1]$

$B = [10, 10]$

Euclidean Distance

$d(A, B) = \sqrt{(10 - 1)^2 + (10 - 1)^2}$

$= \sqrt{81 + 81}$

$= \sqrt{162}$

≈ 12.73

Yani iki nokta birbirinden oldukça uzaktır.

Cosine Similarity

$cos(A, B) = 1$

Çünkü:

$B = 10A$

olduğundan yönleri tamamen aynıdır.

Sonuç:

Euclidean: "Birbirlerinden uzaktalar."

Cosine: "Yön/örüntü olarak tamamen benzerler."

İkisi de doğrudur.

Çünkü farklı sorular sormaktadırlar. HAFTA_02_OGRENCI.pdf

25. Ne Zaman Hangisi Kullanılır?

Euclidean Distance

"İki gözlem sayısal olarak birbirine ne kadar yakın?"

sorusuna uygundur.

Örneğin:

- k-NN
- kümeleme
- tabular veri
- fiziksel koordinatlar

Cosine Similarity

"İki vektör aynı örüntüye/yöne ne kadar sahip?"

sorusuna uygundur.

Örneğin:

- metin benzerliği
- belge karşılaştırma
- öneri sistemleri
- embedding karşılaştırmaları

Özellikle metinlerde belge uzunlukları farklı olabileceğinden cosine similarity yararlıdır.

26. Tabular Verinin Vektöre Dönüştürülmesi

Örneğin:

Yaş	Boy	Kilo
21	175	75

bir satır:

$x = [21, 175, 75]$

şeklinde vektöre dönüştürülebilir.

Burada:

$d = 3$

olur.

Tabular veride genel olarak:

Her satır = gözlem

Her sütun = feature

şeklinde düşünülür.

27. Görüntünün Vektöre Dönüştürülmesi

Gri tonlamalı görüntülerde her piksel:

$0 - 255$

arasında bir sayı olabilir.

Örneğin 2×2 görüntü:

$\begin{bmatrix} 0 & 50 \\ 200 & 255 \end{bmatrix}$

düzleştirildiğinde:

$x = [0, 50, 200, 255]$

olur.

Dimension:

$d = 4$

28×28 gri görüntü için:

$28 \times 28 = 784$

Dolayısıyla:

$d = 784$

RGB görüntüde ise her piksel:

- Red
- Green
- Blue

olmak üzere üç değer içerir.

224×224 RGB görüntü:

$224 \times 224 \times 3$

$= 150528$

sayıyla temsil edilebilir.

28. Metnin Vektöre Dönüştürülmesi

Basit yöntemlerden biri Bag of Words yöntemidir.

Sözlüğümüz:

["veri","bilimi","güzel"]
olsun.
Cümle:

“veri bilimi güzel”

ise:

* veri → 1
* bilimi → 1
* güzel → 1

vektör:

[1,1,1]

olur.

Cümle:

“veri bilimi veri”

ise:

* veri → 2
* bilimi → 1
* güzel → 0

dolayısıyla:

[2,1,0]

olur.

Bag of Words kelimelerin sırasını kaybeder.

Örneğin:

“Köpek adamı ısırdı.”

ve

“Adam köpeği ısırdı.”

aynı kelimeleri içerdiğinden basit Bag of Words yaklaşımında aynı