II. Bölüm - Graph Tabanlı Yöntemler

Metin Özetleme nedir ve neden önemlidir?

* Metin özetleme, uzun bir metindeki önemli bilgileri belirleyerek metni daha kısa ve anlamlı bir temsil dönüştürme işlemidir.
* Günümüzde haberler, akademik makaleler, teknik raporlar gibi çok büyük miktarda metin-sel veri üretmektedir. Bu verilerin tamamı insanlar tarafından okunması zaman alır.

Temel amaç: Ana fikirleri koruyarak metni gereksiz ayrıntı ve tekrarları azaltmak

* Metin özetleme önemli bilgileri ön plana çıkararak:
  - zaman tasarrufu
  - verimlik
  - bilgiye hızlı erişim

sağlar.

* metin özetleme iki temel kategoriye ayrılır:



2.1. Karşılaştırmalı örnek

Orijinal metin:

> Yapay zekâ teknolojileri sağlık, eğitim ve ulaşım alanlarında kullanılmaktadır. Özellikle görüntü işleme sistemleri hastalıkların erken teşhisini kolaylaştırmaktadır. Bunun yanında otonom araçlar ulaşım güvenliğini artırmayı hedeflemektedir.

Extractive özet:

> Yapay zekâ teknolojileri sağlık, eğitim ve ulaşım alanlarında kullanılmaktadır.

Abstractive özet:

> Yapay zekâ, hastalıkların teşhisinden otonom ulaşıma kadar birçok alanda fayda sağlamaktadır.

	Extractive (Çıkarımsal)	Abstractive (Soyutlayıcı)
Çalışma mantığı	Cümle seçimi	Yeni cümle üretimi
Yeni kelime üretme	Hayır	Evet
Hesaplama maliyeti	Genelde düşük	yüksek
Dil akıcılığı	Değişken	Genellikle doğal
Bilgi kaybı	Olabilir	Olabilir.
Örnek yöntem	TextRank, LexRank	Transform Tabanlı Modeller
Eğitim ihtiyacı	Yok	var

Graph Tabanlı Yöntemler (Graph-Based Method)

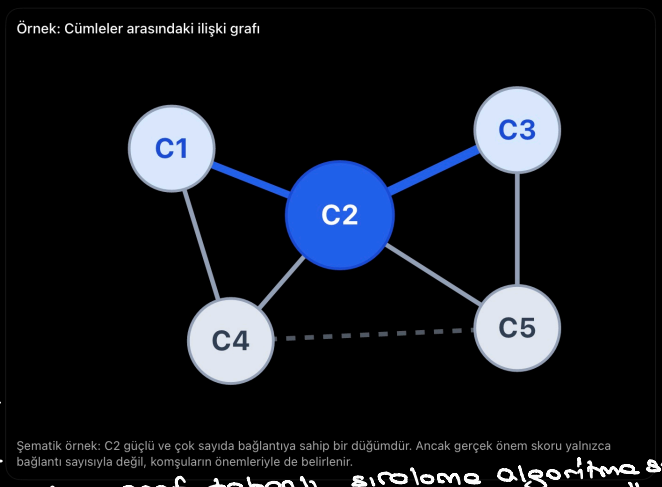
* Graf tabanlı yöntemler, metinsel ögeleri birbiriyle olan ilişkilerinden yararlanarak hangi ögenin daha önemli olduğunu belirler.
* Bir graf matematiksel olarak:

$$G = (V, E)$$

şeklinde hesaplanır.

Burada:

- V = Düğüm (vertex/node) kümesi
- E = Kenar kümesi (Edge)



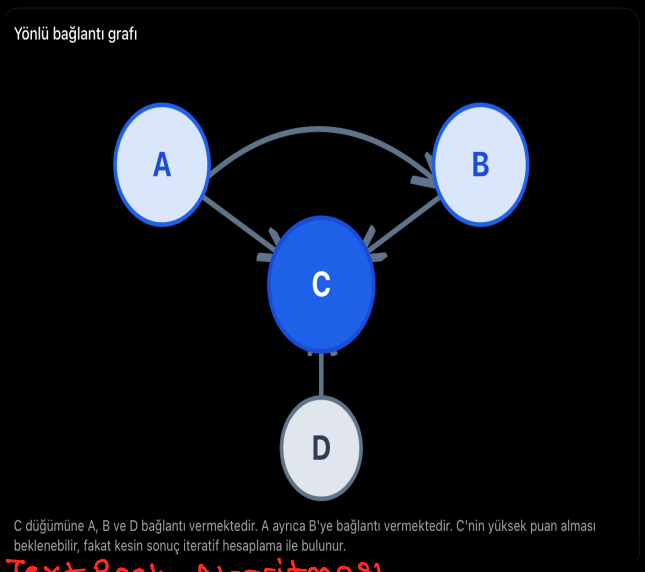
PageRank Algoritması

* PageRank, Google kurucuları Larry Page ve Sergey Brin tarafından geliştirilen, başlangıçta web sayfalarını önemini hesaplamak için kullanılan graf tabanlı sıralama algoritmasıdır.

Temel düşünce: Bir düğümün önemli olması, kendisine bağlantı veren düğümlerinde önemli olmasına bağlıdır.

* PageRank, webi bir grafik gibi modelleyerek sayfaları düğümler, bağlantı ve kenarlar olarak değerlendirir ve bu yapıyı kullanarak her sayfaya "önem skoru" verir.

PageRank Çalışma Mantığı



- PageRankın çalışma mantığı:

1. Düğümlere başlangıç önem skoru verilir.
2. Her düğüm, skorun bir kısmını bağlantı verdiği düğümlere aktarır.
3. Bu işlem skorlar yerleşince kararlı hale kadar iterative hesaplama denir.

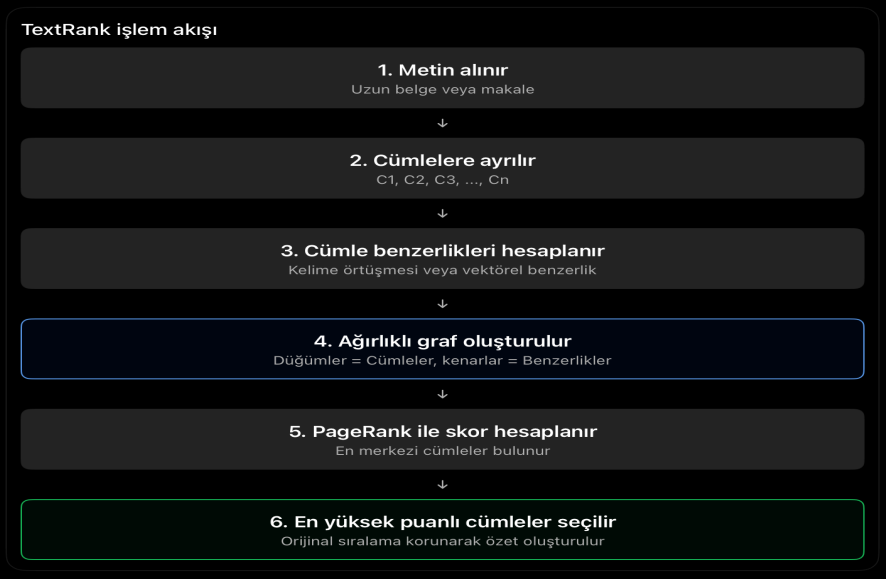
$$PR(V_i) = \frac{1-d}{N} + d \sum \frac{PR(V_j)}{|Out(V_j)|}$$

Sembol	Anlamı
$PR(V_i)$	i düğümünün önem skoru
d	Sönümleme katsayısı (genellikle 0,85)
N	Toplam düğüm sayısı
$In(V_i)$	i düğümüne bağlantı veren düğümler
$Out(V_j)$	j düğümünden çıkan bağlantılar
$\|Out(V_j)\|$	j düğümünün çıkış bağlantısı sayısı

Text Rank Algoritması

* TextRank, Mihalcea ve Tarau tarafından 2004 yılında önerilmiş, Page Rank yaklaşımının metin işleme görevine uyarlayan denetimsiz algoritmadır.
* Text rankın en güçlü yanı etiketlenmiş veriye ihtiyaç duymadan denetimsiz şekilde kelime cümle bilmesidir.

✓ Eğitim verisine ihtiyaç duymaz
✓ Tek belge özetlemeye uygundur.



TextRank Benzerlik Hesaplama

- TextRank farklı benzerlik yöntemleri kullanabilir.
- Klasik yaklaşımda ortak kelime sayısına dayalı ölçüt bulunur.

$$Sim(S_i, S_j) = \frac{|\{w : w \in S_i \cap S_j\}|}{\log(|S_i|) + \log(|S_j|)}$$

$|S_i|$, $|S_j|$ → kelime sayısı

TextRank Avantajları ve Sınırları

Avantajları	Sınırları
Etiketlenmiş eğitim verisi gerekmez	Benzer cümleri tekrar seçebilir.
Tek bir belge için kolaydır.	Yüzeysel benzerlik yetersiz kalabilir.
Farklı dillerde kullanılabilir.	Uzun belgelerde maliyet artabilir
Anahtar kelime çıkarılabilir.	Parametreleri ayarlamak zor olabilir.
Graph üzerinden bütüncül önlem hesaplar	Ön işleme kalitesinden etkilenir.

LexRank Algoritması

*LexRank, Erkan ve Radev tarafından geliştirilen, özellikle çok belgeli metin özetleme için kullanılan graph tabanlı denetimsiz algoritmadır.

* TextRanka benzer şekilde çalışır; ancak LexRank, cümleler arasındaki ilişkiyi ölçmek için TD-IDF vektörleri ve kosinüs benzerliğini kullanır.

*Her cümle, graf yapısında düğüm (node) olarak kabul edilir. Cümler arası benzerlik hesaplanarak kenarlar oluşturulur.

* LexRank, benzerlik hesaplamasında TF-IDF tabanlı kosinus benzerliği kullanır. Bu sayede, sık geçen genel kelimeleri daha düşük, ayırt edici kelimeler benzerlik skorunu daha çok yükseltir.

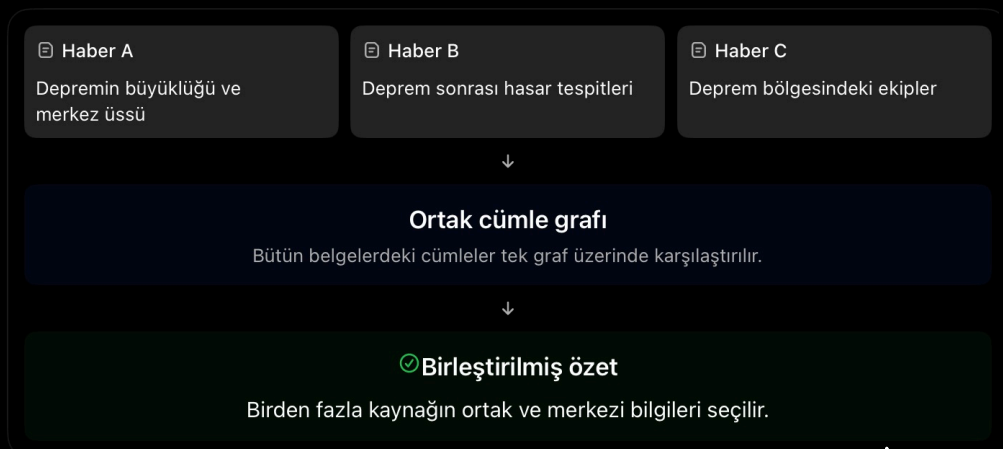
LexRank - Eşik değer Uygulanması

- Benzerlik matrisine eşik değer uygulanır.
- Eşik değerin altındaki değerler alınmaz.
- Bu yaklaşım zayıf bağlantıları grafikten çıkarmayı sağlar. Sonuç olarak seyrek ve anlamlı bir grafik yapısı ortaya çıkar. Bu da cümlelerin daha belirgin küme oluşmasını sağlar.

LexRank - Kenar Ağırlıkları

- Eşik uygulandıktan sonra, grafik kenarlar çoğunlukla ağırlıksız kabul edilir.
- Bu süreç cümlelerin "yeterince benzer" olup olmadığını vurgular. Eşik üzerinden benzerlik skorları doğrudan kullanılır.

LexRank ile Çoklu Belge Özetleme



1. Birden fazla belgeden oluşan bir belge kümesini tek bir grafik yapısında birleştirir.
2. Grafik üzerinde en merkezi cümleler seçilerek özet oluşur.
3. Bu durumda TD-IDF vektörleri tüm belgeleri birlikte düşünülerek hesaplanır.
4. Cümlelerin farklı belgelerdeki diğer cümlelerle olan benzerlikleri, o cümle önem derecelerini belirler

LexRank Avantajları ve Sınırlıkları

Avantajları	Sınırları
Çok belgeli özetleme için doğal uyum sağlar	Yüzeysel eşleşmeye dayanır.
TD-IDF tabanlı benzerlik, ortak önemleri bulur	Eşik değeri kritik parametredir.
Eşik değeri ile grafik seyrekleştirebilir.	Hiperparametre ayarı gerekir.
Gürültü azaltımı sağlar	TF-IDF belge koleksiyonuna ihtiyaç duyar.
Eğitim gerektirmez, dilden bağımsızdır	Kısa metinlerde sınırlı kalabilir.
Nadir ama anlamlı kelimeleri öne çıkar	Redundans kontrolü yer almaz
Pratikte yaygın kullanılır.	Ek filtreleme mekanizması gerekebilir.

TEXTRANK VE LEXRANK – ORTAK YÖNLER

- Her iki algoritma da **graf tabanlı rastgele gezinme (random walk)** prensibine dayanır.
- Her ikisi de, **PageRank algoritmasının doğal dil işlemeye uyarlanmış versiyonlarıdır**.
- Metindeki her cümle, bir **düğüm (node)** olarak temsil edilir.
- Cümleler arası **benzerlik ilişkileri**, graf üzerinde **kenar (edge)** olarak modellenir.
- Grafik üzerinde PageRank uygulanarak cümlelerin önem sırası belirlenir.
- "**Birbirini öneren cümleler daha önemlidir**" anlayışı her iki yöntemde de temeldir.
- Her ikisi de **denetimsiz (unsupervised)** yöntemlerdir.