ROBOTİK DERSİ
VİZE ÇALIŞMA SORULARI

CEVAP ANAHTARI

Bu anahtar, 46 soruluk klasik çalışma kâğıdındaki sorularla aynı sırayı izler. Cevaplar örnek yanıt niteliğindedir; açık uçlu sorularda eşdeğer ve doğru gerekçelendirilmiş ifadeler de kabul edilebilir.

I. Doğal Dil İşleme ve Temel Dilbilim Kavramları

1. Doğal Dil İşleme (NLP) ve metin madenciliği arasındaki fark

NLP, insan dilini bilgisayarlarla analiz etme, anlama ve üretme alanıdır. Duygu analizi, varlık tanıma ve soru-cevap sistemleri örnektir. Metin madenciliği ise yapılandırılmamış metinlerden istatistiksel bilgi, eğilim ve örüntü çıkarmaya odaklanır. Örneğin binlerce müşteri yorumunda en sık şikâyet edilen konuların bulunması metin madenciliğidir.

2. Sentaks, semantik, pragmatik, çok anlamlılık ve gönderim

Sentaks cümlenin yapısını ve kelimeler arasındaki dilbilgisel ilişkileri inceler. Semantik sözcük ve cümle anlamıyla ilgilenir. Pragmatik, anlamı bağlam ve konuşmacı niyetine göre yorumlar. “Yüz” kelimesinin sayı veya insan yüzü anlamına gelebilmesi çok anlamlılıktır. “Ayşe geldi. O çok mutlu.” örneğinde “O” zamirinin Ayşe'ye gönderimde bulunması coreference/gönderim çözümlemesidir.

3. Türkçenin eklemeli yapısının NLP'ye etkisi

Türkçede köke çok sayıda yapım ve çekim eki eklenerek farklı sözcük biçimleri üretilebilir. Bu durum sözlük/özellik uzayını büyütür, aynı kökün farklı biçimlerinin ayrı kelimeler gibi algılanmasına ve seyrekliğe neden olabilir. Morfolojik çözümleme, kökü ve ekleri ayırarak kişi, zaman, çoğul, olumsuzluk ve kip gibi bilgileri belirlemeye yardımcı olur.

4. Stemming ve lemmatization karşılaştırması

Stemming, çoğunlukla sezgisel kurallarla sözcüğün sonundaki ekleri keserek köke benzer bir biçim üretir; ortaya çıkan biçim her zaman sözlükte bulunan gerçek bir kelime olmayabilir. Lemmatization ise dilbilgisel ve sözlüksel bilgiyi kullanarak sözcüğü sözlükteki temel biçimine dönüştürür. Örneğin İngilizcede “running” için stemming “run” benzeri bir çıktı verirken lemmatization da sözlük biçimi olan “run” sonucuna ulaşabilir; “better” için lemmatization “good” sonucunu verebilir.

5. Stop-word ve 'değil' örneği

Stop-word, birçok metinde sık görülen ve bazı görevlerde ayırt edici bilgi taşımayan kelimelerdir. Ancak her görevde otomatik olarak silinmemelidir. “Ürün iyi” ile “Ürün iyi değil” cümlelerinde “değil” kelimesi olumsuzluğu belirler. Silinmesi duygu yönünü ters veya hatalı yorumlatabilir.

6. Temel metin ön işleme adımları

Tokenizasyon metni kelime veya alt kelime birimlerine ayırır. Küçük harfe dönüştürme büyük-küçük harf farklılıklarını azaltır. Noktalama temizliği gürültüyü azaltabilir. Kök bulma/lemmatization sözcük biçimlerini birleştirmeye yardımcı olur. Ancak ünlem, büyük harf veya noktalama duygu analizinde anlamlı olabileceğinden ön işlemler görev ve veri türüne göre seçilmelidir.

II. Metin Temsili ve Özellik Çıkarma

7. Bag-of-Words yaklaşımı

BoW, metni sözlükteki kelimelerin varlığı veya sıklığına göre sayısal vektörle temsil eder. Her boyut bir kelimeyi temsil eder. Basit ve uygulanabilir olmasına karşın kelime sırasını, sözdizimini ve bağlamı büyük ölçüde kaybeder; “köpek insanı ısırdı” ile “insan köpeği ısırdı” gibi cümleleri benzer temsil edebilir.

8. TF, IDF ve TF-IDF

TF kelimenin belirli bir belge içindeki sıklığını; IDF kelimenin tüm belge koleksiyonunda ne kadar nadir/ayırt edici olduğunu ifade eder. Yaygın bir formül IDF(t)=log(N/df(t)) biçimindedir. TF-IDF, TF ile IDF'nin çarpımıdır. Bir kelime belgede sık fakat tüm koleksiyonda da çok yaygınsa IDF düşük olur ve kelimenin ayırt edici ağırlığı azalır.

9. Unigram, bigram ve trigram

Unigram tek kelimelik, bigram ardışık iki kelimelik, trigram ardışık üç kelimelik özellik dizisidir. N-gramlar “hiç iyi değil” gibi yerel kelime dizilerini ve olumsuzluk kalıplarını yakalayabilir. Ancak n arttıkça olası özellik sayısı, bellek/hesaplama ihtiyacı ve seyrekleşme ile aşırı öğrenme riski artabilir.

10. Word2Vec ve embedding

Embedding kelimeleri yoğun, sayısal vektörlerle temsil eder. Word2Vec, benzer bağlamlarda kullanılan kelimelerin vektör uzayında yakın olabileceği dağıtımsal varsayıma dayanır. BoW/TF-IDF çoğunlukla kelime sıklığı ve ayırt ediciliğine odaklanırken embedding anlamsal yakınlıkları geometrik olarak temsil etmeye çalışır.

11. Bağlamsal ve bağlamdan bağımsız temsiller

Word2Vec gibi klasik kelime embedding'leri bir kelimeye genellikle tek bir sabit vektör verir; çok anlamlı kelimeler için bu sınırlayıcıdır. BERT gibi bağlamsal modeller kelimenin temsilini çevresindeki kelimelere göre oluşturur. Böylece “banka” kelimesinin finans kurumu veya nehir kıyısı anlamı bağlama göre farklı temsil edilebilir.

III. Metin Sınıflandırma ve Makine Öğrenmesi

12. Metin sınıflandırma ve problem türleri

Metin sınıflandırma, bir metin örneğine önceden tanımlanmış etiket/etiketler atama problemidir. İkili sınıflandırmada iki sınıf vardır (spam/spam değil). Çok sınıflı sınıflandırmada her örnek birden fazla olası sınıftan yalnızca birine atanır (spor/ekonomi/siyaset). Çok etiketli sınıflandırmada aynı metin birden fazla etiketi birlikte alabilir (sağlık ve yapay zekâ).

13. Metin sınıflandırma işlem hattı

Genel hat: veri toplama, etiketleri oluşturma/kontrol etme, eğitim-doğrulama-test ayrımı, ön işleme ve sayısal temsil, model eğitimi, uygun metriklerle değerlendirme ve hata analizi. Sözlük öğrenme, ölçekleme ve benzeri veriden parametre öğrenen işlemler yalnızca eğitim verisi üzerinde öğrenilmeli; test verisi bağımsız değerlendirme için saklanmalıdır.

14. Veri sızıntısı

Veri sızıntısı, test veya doğrulama kümesine ait bilginin eğitim sürecine doğrudan ya da dolaylı biçimde karışmasıdır. Örneğin tüm veri üzerinde sözlük/özellik seçimi yapıp sonra bölmek, test verisinin özellik dağılımını eğitime taşır. Modelin gerçek hayattaki başarısı olduğundan yüksek görünebilir. Önce veri bölünmeli, öğrenilen dönüşümler eğitim verisine fit edilip diğer kümelere uygulanmalıdır.

15. Naive Bayes

Naive Bayes, Bayes teoremini kullanarak bir metnin her sınıfa ait olma olasılığını hesaplar. Temel varsayımı, sınıf bilindiğinde özelliklerin/kelimelerin koşullu olarak bağımsız olmasıdır. Doğal dilde kelimeler bağımsız olmasa da yüksek boyutlu metin verisinde sınıflar arasındaki kelime kullanım farklarını basit ve düşük varyanslı biçimde yakalayabilir.

16. Lojistik regresyon

Lojistik regresyon özelliklerin ağırlıklı toplamından doğrusal bir skor üretir ve sigmoid/softmax gibi fonksiyonlarla sınıf olasılığına dönüştürür. TF-IDF ile sık kullanılır. Öğrenilen katsayılar bir kelimenin belirli sınıf yönündeki karar skoruna katkısını yorumlamaya yardımcı olur. L1/L2 düzenlileştirme aşırı öğrenmeyi azaltmaya katkı sağlayabilir.

17. SVM ve maksimum marjin

SVM, sınıfları ayıran karar sınırını iki sınıfa en yakın örnekler arasındaki marjini mümkün olduğunca genişletecek şekilde belirler. Marjin, karar sınırına en yakın örneklerle sınır arasındaki güvenlik boşluğudur. Metin temsilleri çoğunlukla yüksek boyutlu ve seyrek olduğundan doğrusal SVM bu uzaylarda güçlü ayrımlar bulabilir.

18. Naive Bayes, lojistik regresyon ve SVM karşılaştırması

Naive Bayes olasılıksal ve koşullu bağımsızlık varsayımlı bir yöntemdir. Lojistik regresyon doğrusal karar skorunu olasılığa dönüştürür ve katsayıları yorumlanabilir. SVM maksimum marjinli karar sınırı öğrenir. Üçü de TF-IDF gibi seyrek metin temsilleriyle kullanılabilir; yöntem seçimi veri miktarı, doğruluk, yorumlanabilirlik ve hesaplama koşullarına bağlıdır.

19. Gözetimli, gözetimsiz ve pekiştirmeli öğrenme

Gözetimli öğrenme etiketli (X,y) örneklerden ilişki öğrenir; spam sınıflandırma örnektir. Gözetimsiz öğrenme etiketsiz veride yapı veya kümeler keşfeder; haberleri konu benzerliğine göre kümelemek örnektir. Pekiştirmeli öğrenmede ajan ortamla etkileşir, eylemlerine ödül/ceza alarak politika öğrenir; ödül-ceza ile eğitilen bir diyalog ajanı örnek verilebilir.

20. Embedding, CNN, RNN/LSTM ve Transformer

Embedding kelimeleri vektörlere dönüştürür. CNN filtrelerle yerel kelime/n-gram örüntülerini yakalar. RNN/LSTM diziyi sıralı işler ve önceki bağlam bilgisini taşımaya çalışır. Transformer self-attention ile dizideki öğeler arasındaki ilişkileri paralel biçimde modelleyebilir. Her yaklaşımın veri, hesaplama ve bağlamı yakalama özellikleri farklıdır.

21. Self-attention

Self-attention, dizideki her kelimenin diğer kelimelerle ilişkisine ağırlık vermesini sağlar. Böylece model bir kelimeyi yorumlarken cümlenin farklı konumlarındaki ilgili kelimelere odaklanabilir. Uzak bağımlılıkların ve bağlama bağlı anlamın yakalanmasını kolaylaştırır.

22. BERT ön eğitim ve ince ayar

BERT büyük metin koleksiyonlarında ön eğitimle dil örüntülerini ve bağlamsal temsilleri öğrenir. Daha sonra sınıflandırma gibi hedef görev için etiketli veri üzerinde ince ayar yapılır; genellikle özel sınıflandırma katmanı eklenir. Transfer öğrenme, görev verisi sınırlı olduğunda önceden öğrenilmiş dil bilgisinden yararlanmayı sağlar. Yine de veri dengesizliği, öğrenme oranı ve aşırı uyum kontrol edilmelidir.

IV. Model Değerlendirme ve Veri Problemleri

23. Accuracy, precision, recall ve F1

Accuracy tüm örnekler içinde doğru tahmin oranıdır: (TP+TN)/(TP+TN+FP+FN). Precision pozitif tahminlerin ne kadarının doğru olduğunu gösterir: TP/(TP+FP). Recall gerçek pozitiflerin ne kadarının bulunduğunu gösterir: TP/(TP+FN). F1, precision ve recall'un harmonik ortalamasıdır: 2PR/(P+R).

24. Sınıf dengesizliği ve accuracy

Sınıf dengesizliğinde bir sınıf diğerlerinden çok daha fazla örneğe sahiptir. Örneğin verinin %95'i spam değilse her örneğe spam değil diyen model %95 accuracy alabilir, ancak spam örneklerini hiç bulamayabilir. Bu nedenle precision, recall, F1 ve sınıf bazlı sonuçlar da incelenmelidir.

25. Macro-F1 ve Micro-F1

Macro-F1 her sınıfın F1 değerini ayrı hesaplayıp sınıflara eşit ağırlıkla ortalamasını alır; azınlık sınıfların başarısını görünür kılar. Micro-F1 tüm sınıflardaki TP, FP ve FN değerlerini birleştirerek hesaplanır; örnek sayısı fazla olan sınıflar sonucu daha fazla etkileyebilir.

26. Eğitim başarısı yüksek, test başarısı düşükse

Bu durum aşırı öğrenme (overfitting), eğitim-test dağılımı farkı, veri sızıntısı/yanlış bölme veya yetersiz veri gibi sorunlara işaret edebilir. Model eğitim örneklerini ezberlemiş fakat görmediği örneklere genelleyemiyor olabilir. Düzenlileştirme, daha iyi veri bölme, çapraz doğrulama ve hata analizi kullanılabilir.

27. Domain shift

Domain shift, eğitim ve test verilerinin dağılımlarının farklılaşmasıdır. Sosyal medya kısa, yazım hatalı ve gündelik ifadeler içerebilir; akademik metinler uzun, biçimsel ve teknik terimlerle doludur. Kelime ve bağlam dağılımları değiştiği için sosyal medyada öğrenilen örüntüler akademik metinlerde işe yaramayabilir.

28. Hata analizi

Hata analizi yanlış sınıflandırılmış örnekleri inceleyerek modelin neden hata yaptığını anlamayı sağlar. İroni, kısa metin, yazım hatası, çok anlamlı kelimeler veya alan terimleri hataya neden olabilir. Ortak hata örüntüleri belirlenerek veri, temsil, model veya etiketleme süreci iyileştirilebilir.

29. Veri yanlılığı, açıklanabilirlik, gizlilik ve adalet

Eğitim verisi belirli grupları veya görüşleri sistematik biçimde yanlış temsil ederse model bu yanlılığı öğrenebilir. Özellikle işe alım veya sağlık gibi alanlarda hatalı ve açıklanamayan kararlar zarar doğurabilir. Veri gizliliği, kullanıcı rızası, açıklanabilirlik ve gruplar arasında adil performans değerlendirmesi gözetilmelidir.

V. Metin Özetleme ve Graf Tabanlı Yöntemler

30. Metin özetlemenin önemi

Dijital ortamda metin ve bilgi miktarı hızla artarken insanların okuma zamanı sınırlıdır. Otomatik özetleme uzun belgelerdeki önemli bilgileri kısa biçimde sunarak zaman tasarrufu ve bilgiye hızlı erişim sağlar. Haber, akademik makale, e-posta ve raporlar önemli kullanım alanlarıdır.

31. Extractive ve abstractive özetleme

Extractive özetleme kaynak metindeki önemli cümleleri değiştirmeden seçer; hızlı ve görece basittir ancak tekrar veya kopukluk içerebilir. Abstractive özetleme metni anlayıp yeni cümlelerle yeniden ifade eder; daha doğal olabilir fakat dil üretimi, model ve hesaplama açısından daha karmaşıktır.

32. Graf tabanlı sıralama

Graf, düğümler ve kenarlardan oluşur. Metin özetlemede cümleler düğüm, cümleler arasındaki benzerlikler kenar olarak modellenebilir. Kenar ağırlığı benzerliğin gücünü gösterebilir. Böylece metnin merkezinde bulunan, diğer önemli cümlelerle güçlü ilişkisi olan cümleler sıralanabilir.

33. PageRank

PageRank web sayfalarını düğüm, bağlantıları kenar olarak değerlendirir. Bir sayfanın önemi yalnızca aldığı bağlantı sayısına değil, bağlantı veren sayfaların önemine de bağlıdır. Bu fikir TextRank ve LexRank'te cümlelerin önemini belirlemek için kullanılır.

34. TextRank adımları

Önce belge cümlelere ayrılır. Her cümle bir düğüm olur. Cümleler arasındaki benzerlikler hesaplanarak kenarlar/ağırlıklar oluşturulur. Graf üzerinde PageRank benzeri iteratif skor güncellemesi yapılır. Yüksek skorlu cümleler, genellikle özgün metindeki sıraları korunarak özet olarak seçilir.

35. TextRank'te bağlantı ve damping factor

Bir cümle önemli cümlelerle güçlü bağlantılara sahipse kendi önem skoru da artabilir. Damping factor, rastgele gezinme modelinde bağlantıları takip etme ile başka bir düğüme geçme olasılığını dengeleyen katsayıdır. Ders notunda yaygın değer olarak 0,85 verilmiştir.

36. LexRank çalışma mantığı

Her cümle TF-IDF vektörüyle temsil edilir. Cümle çiftleri arasındaki kosinüs benzerliği hesaplanır. Belirlenen eşik üzerindeki benzerlikler arasında kenar oluşturularak genellikle yönsüz bir graf kurulur. Graf üzerinde PageRank benzeri sıralama yapılır ve yüksek skorlu cümleler seçilir.

37. LexRank threshold

Eşik, zayıf benzerlikteki cümle çiftlerinin graf bağlantısı olmasını önler. Çok düşük eşik çok sayıda zayıf kenar oluşturarak grafı gürültülü/yoğun yapabilir. Çok yüksek eşik anlamlı bağlantıları da kaldırıp grafı seyrek veya parçalı hale getirebilir. Uygun değer deneysel seçilmelidir.

38. TextRank ve LexRank karşılaştırması

İkisi de PageRank fikrini cümlelere uygulayan denetimsiz graf tabanlı yöntemlerdir. TextRank'te cümle benzerliği farklı ölçütlerle kurulabilir ve tek belge özetlemede yaygın kullanılır. LexRank özellikle TF-IDF ve kosinüs benzerliği ile eşik tabanlı kenar oluşturmayı vurgular; çok belgeli özetleme için uygundur. Her ikisi de anlamsal parafrazları kaçırabilir ve tekrar üretebilir.

39. Denetimsiz olma özelliği

Denetimsiz yöntemler, önceden etiketlenmiş eğitim örneklerine ihtiyaç duymadan verinin kendi yapısından yararlanır. TextRank ve LexRank, cümle benzerlik grafı üzerinden önem sıralaması yapar. Bu özellik farklı metinlere uygulanmalarını kolaylaştırır; ancak her metinde en iyi özeti garanti etmez.

40. Yüzeysel benzerliğin sınırlılıkları

Kelime örtüşmesi veya TF-IDF benzerliği, aynı anlamın farklı kelimelerle ifade edildiği parafrazları kaçırabilir. Eş anlamlı kelimeler düşük benzerlik alabilir. Buna karşılık aynı kelimeleri tekrarlayan ama içerikçe gereksiz cümleler yüksek benzerlik alabilir. Bu nedenle anlamsal embedding ve tekrar azaltma yöntemleriyle desteklenebilir.

41. LexRank ile çok belgeli özetleme

Birden fazla belgedeki tüm cümleler tek bir grafın düğümleri olarak ele alınır. TF-IDF vektörleri belge koleksiyonu üzerinden oluşturulur; cümleler arası benzerliklerle kenarlar kurulur. Merkezi ve yüksek skorlu cümleler seçilerek farklı kaynaklardaki ortak önemli bilgiler tek özette birleştirilebilir.

VI. Sayısal ve Uygulamalı Soruların Çözümleri

42. TF-IDF hesaplama

Verilenler: N=10, df=2, TF=3. IDF=$\log_{10}(N/df)=\log_{10}(10/2)=\log_{10}(5)\approx 0{,}699$.
TF-IDF=TF×IDF=3×0,699≈2,097. Burada soruda belirtildiği gibi ham frekans TF olarak kullanılmıştır.

43. Confusion matrix metrikleri

TP=40, FP=10, FN=20, TN=130; toplam=200. Accuracy=(TP+TN)/200=(40+130)/200=0,85=%85.
Precision=TP/(TP+FP)=40/50=%80. Recall=TP/(TP+FN)=40/60≈%66,67.
F1=2×Precision×Recall/(Precision+Recall)=2×0,8×0,6667/(0,8+0,6667)≈0,7273=%72,73.

44. Kosinüs benzerliği

A=(1,2,0), B=(2,1,0). İç çarpım A·B=1×2+2×1+0×0=4. Normlar $||A||=\sqrt{1^2+2^2}=\sqrt{5}$ ve $||B||=\sqrt{2^2+1^2}=\sqrt{5}$.
cos(A,B)=4/(√5×√5)=4/5=0,8. Değer 1'e yakın olduğundan vektörler yüksek ölçüde benzer yönlüdür.

45. LexRank eşiği ve düğüm dereceleri

Eşik 0,50 olduğundan 0,50'ye eşit veya büyük bağlantılar alınır. S1-S2=0,80 ve S2-S3=0,60 kenarları oluşur; S1-S3=0,25 elenir. Dereceler: S1=1, S2=2, S3=1. En yüksek derece S2 düğümündedir. Bu derece hesabıdır; tam LexRank/PageRank skor hesabı değildir.

46. TextRank/PageRank tek güncelleme

d=0,85. A katkısı 0,6/2=0,3; B katkısı 0,3/1=0,3. Katkıların toplamı 0,6'dır. S(V)=(1-0,85)+0,85×0,6=0,15+0,51=0,66. Sonuç, soruda verilen sadeleştirilmiş formüle göre tek güncelleme adımıdır.