ROBOTİK DERSİ
VİZE ÇALIŞMA KÂĞIDI

46 klasik soru • Her sorunun altında cevap yazma alanı

Ad Soyad: ..... Tarih: .....

Yönerge: Soruları açıklayıcı ve gerekçeli biçimde cevaplayınız. Sayısal sorularda işlem basamaklarını gösteriniz. Bu PDF'de cevaplar verilmemiştir; her sorunun altında kendi yanıtınızı yazmanız için boş alan bırakılmıştır.

I. Doğal Dil İşleme ve Temel Dilbilim Kavramları

1. Doğal Dil İşleme (NLP) ve metin madenciliği kavramlarını tanımlayınız. Amaçları, odaklandıkları problemler ve uygulama alanları bakımından aralarındaki farkları açıklayınız.

2. Sentaks, semantik ve pragmatik kavramlarını tanımlayınız. “Yüz” kelimesinin sayı ve insan yüzü anlamlarına gelebilmesini çok anlamlılık açısından; “Ayşe geldi. O çok mutlu.” örneğini ise gönderim (coreference) açısından açıklayınız.

3. Türkçenin sondan eklemeli morfolojik yapısının doğal dil işleme sistemlerinde oluşturduğu zorlukları açıklayınız. Eklemeli bir sözcüğün kök, ekler ve taşıdığı dilbilgisel bilgiler bakımından nasıl çözümlenebileceğini tartışınız.

4. Stemming (kök bulma) ve lemmatization (sözlük biçimine indirgeme) yöntemlerini tanımlayınız. Çalışma mantıkları, ürettikleri çıktılar ve hata ihtimalleri bakımından karşılaştırınız.

5. Stop-word kavramını açıklayınız. Duygu analizi gibi bir görevde “değil” kelimesinin durak kelime olarak silinmesinin sonuçlarını örnekle açıklayınız.

6. Tokenizasyon, küçük harfe dönüştürme, noktalama işaretlerini temizleme ve kök bulma işlemlerinin metin ön işleme sürecindeki rollerini açıklayınız. Her ön işlemin her problemde yararlı olup olmayacağını tartışınız.

II. Metin Temsili ve Özellik Çıkarma

7. Bag-of-Words (BoW) yaklaşımını açıklayınız. Bir metnin sayısal vektöre dönüştürülmesi sürecini ve bu yaklaşımın kelime sırası ile bağlam bakımından temel sınırlılığını belirtiniz.

8. TF, IDF ve TF-IDF kavramlarını tanımlayınız. Bir kelimenin belge içinde sık geçmesine rağmen tüm belge koleksiyonunda yaygın olması durumunda TF-IDF ağırlığının nasıl etkileneceğini açıklayınız.

9. Unigram, bigram ve trigram kavramlarını açıklayınız. N-gram kullanımının metin sınıflandırmaya sağladığı katkıları ve özellik uzayının büyümesiyle ortaya çıkabilecek sorunları tartışınız.

10. Word2Vec gibi embedding yöntemlerinin temel fikrini açıklayınız. Kelimelerin yoğun vektörlerle temsil edilmesinin BoW ve TF-IDF temsillerinden farklarını belirtiniz.

11. Bağlamsal temsil ile bağlamdan bağımsız kelime embedding'lerini karşılaştırınız. Aynı kelimenin farklı cümlelerde farklı anlamlara gelmesi durumunda BERT gibi Transformer tabanlı modellerin nasıl avantaj sağlayabileceğini açıklayınız.

III. Metin Sınıflandırma ve Makine Öğrenmesi

12. Metin sınıflandırma problemini tanımlayınız. İkili sınıflandırma, çok sınıflı sınıflandırma ve çok etiketli sınıflandırma türlerini örneklerle açıklayınız.

13. Bir metin sınıflandırma sisteminin işlem hattını veri toplamadan hata analizine kadar sırasıyla açıklayınız. Eğitim ve test verilerinin ayrılmasının neden önemli olduğunu belirtiniz.

14. Veri sızıntısı (data leakage) kavramını açıklayınız. Sözlük oluşturma veya özellik ölçekleme gibi işlemlerin eğitim-test ayrımından önce tüm veri üzerinde yapılması neden hatalı sonuçlara yol açabilir?

15. Naive Bayes sınıflandırıcısının çalışma mantığını ve sınıf koşullu bağımsızlık varsayımını açıklayınız. Bu varsayım gerçek dilde tam karşılanmasa bile yöntemin neden etkili olabildiğini tartışınız.

16. Lojistik regresyonun metin sınıflandırmadaki çalışma mantığını açıklayınız. Modelin doğrusal skorları sınıf olasılıklarına nasıl dönüştürdüğünü ve özellik ağırlıklarının yorumlanabilirliğe katkısını belirtiniz.

17. Destek Vektör Makineleri (SVM) yöntemini açıklayınız. Maksimum marjin kavramının ne anlama geldiğini ve yüksek boyutlu metin verilerinde doğrusal SVM'nin neden başarılı olabildiğini tartışınız.

18. Naive Bayes, lojistik regresyon ve SVM yöntemlerini temel varsayımları, karar verme biçimleri ve güçlü yönleri bakımından karşılaştırınız.

19. Gözetimli öğrenme, gözetimsiz öğrenme ve pekiştirmeli öğrenme yaklaşımlarını tanımlayınız. Her biri için doğal dil işleme veya metin analizi alanından bir örnek veriniz.

20. Embedding, CNN, RNN/LSTM ve Transformer yaklaşımlarının metin sınıflandırmada hangi tür bilgileri yakalamaya çalıştığını açıklayınız. Temel farklarını karşılaştırınız.

21. Self-attention mekanizmasını açıklayınız. Bir kelimenin cümledeki diğer kelimelerle ilişkisini değerlendirmesinin bağlamı anlamaya nasıl katkı sağladığını belirtiniz.

22. BERT tabanlı bir modelin ön eğitim (pre-training) ve ince ayar (fine-tuning) aşamalarını açıklayınız. Transfer öğrenmenin özellikle sınırlı etiketli veri bulunan durumlarda sağlayabileceği avantajları tartışınız.

IV. Model Değerlendirme ve Veri Problemleri

23. Accuracy, precision, recall ve F1-score ölçütlerini tanımlayınız. Bu ölçütlerin hangi tür hata veya başarı durumlarını öne çıkardığını açıklayınız.

24. Sınıf dengesizliği (class imbalance) problemini açıklayınız. Veri kümesinin büyük çoğunluğu tek bir sınıftan oluştuğunda yalnızca accuracy kullanmanın neden yanıltıcı olabileceğini örnekle tartışınız.

25. Macro-F1 ve Micro-F1 ölçütlerini karşılaştırınız. Azınlık sınıfların başarısını değerlendirmek için Macro-F1'in neden yararlı olabileceğini açıklayınız.

26. Modelin eğitim verisinde yüksek, test verisinde düşük başarı göstermesi ne anlama gelebilir? Aşırı öğrenme (overfitting), veri dağılımı ve genelleme kavramları üzerinden açıklayınız.

27. Domain shift (alan/dağılım kayması) kavramını açıklayınız. Sosyal medya metinleri üzerinde eğitilen bir modelin akademik metinlerde neden performans kaybı yaşayabileceğini tartışınız.

28. Metin sınıflandırmada hata analizi neden gereklidir? İroni, yazım hataları, kısa metinler ve alan terimleri gibi örnekler üzerinden yanlış sınıflandırmaların olası nedenlerini açıklayınız.

29. Metin sınıflandırma sistemlerinde veri yanlılığı, açıklanabilirlik, gizlilik ve adalet konularının önemini bir uygulama senaryosu üzerinden tartışınız.

V. Metin Özetleme ve Graf Tabanlı Yöntemler

30. Metin özetlemenin günümüzde neden önemli olduğunu açıklayınız. Bilgi miktarının artması ve kullanıcıların sınırlı zamanı arasındaki ilişkiyi değerlendiriniz.

31. Extractive (çıkarımsal) ve abstractive (soyutlayıcı) özetleme yöntemlerini tanımlayınız. Çalışma mantığı, üretilen özetin yapısı, avantajları ve sınırlılıkları bakımından karşılaştırınız.

32. Graf tabanlı sıralama yaklaşımının temel mantığını açıklayınız. Metindeki cümlelerin düğüm, cümleler arasındaki benzerliklerin kenar olarak modellenmesi ne anlama gelir?

33. PageRank algoritmasının temel çalışma fikrini açıklayınız. Bir düğümün öneminin yalnızca aldığı bağlantı sayısına değil, bağlantı veren düğümlerin önemine de bağlı olmasını yorumlayınız.

34. TextRank algoritmasının çalışma adımlarını sırasıyla açıklayınız. Cümlelerin düğüm olarak temsil edilmesi, benzerlik grafının oluşturulması, PageRank skorlarının hesaplanması ve özet cümlelerinin seçilmesi aşamalarını belirtiniz.

35. TextRank'te bir cümlenin önemli kabul edilmesinde diğer önemli cümlelerle bağlantısının nasıl rol oynadığını açıklayınız. Sönümleme katsayısının (damping factor) genel işlevini belirtiniz.

36. LexRank algoritmasının çalışma mantığını açıklayınız. Cümlelerin TF-IDF vektörleriyle temsil edilmesi ve kosinüs benzerliğiyle karşılaştırılması aşamalarını anlatınız.

37. LexRank'te benzerlik eşiği (threshold) kullanılmasının amacını açıklayınız. Eşik değerinin çok düşük veya çok yüksek seçilmesinin graf yapısına etkilerini tartışınız.

38. TextRank ve LexRank algoritmalarını cümle benzerliği hesabı, graf oluşturma, tek/çok belgeli özetleme uygunluğu ve sınırlılıkları bakımından karşılaştırınız.

39. TextRank ve LexRank yöntemlerinin denetimsiz (unsupervised) olmasının ne anlama geldiğini açıklayınız. Bu özelliğin farklı metin türlerine uygulanabilirlik bakımından sağladığı avantajları belirtiniz.

40. Graf tabanlı özetleme yöntemlerinde yüzeysel kelime benzerliğine dayanmanın doğurabileceği sorunları açıklayınız. Eş anlamlı ifadeler, parafraz ve tekrar eden cümleler üzerinden örnek veriniz.

41. LexRank'in çok belgeli özetlemede kullanımını açıklayınız. Farklı belgelerdeki cümlelerin tek bir graf içinde değerlendirilmesiyle ortak ve merkezi bilgilerin nasıl seçilebileceğini anlatınız.

VI. Sayısal ve Uygulamalı Klasik Sorular

42. Bir belge koleksiyonunda toplam 10 belge vardır. “robot” kelimesi 2 belgede geçmekte ve incelenen belgede 3 kez kullanılmaktadır. TF değerini ham frekans, IDF değerini $\log_{10}(N/df)$ olarak alarak TF-IDF değerini hesaplayınız. İşlem basamaklarını gösteriniz.

43. Bir spam sınıflandırma modelinde TP=40, FP=10, FN=20 ve TN=130 olarak verilmiştir. Accuracy, precision, recall ve F1-score değerlerini ayrı ayrı hesaplayınız ve sonuçları yorumlayınız.

44. İki cümleye ait TF-IDF vektörleri A=(1,2,0) ve B=(2,1,0) şeklindedir. Kosinüs benzerliğini hesaplayınız ve bulunan değerin cümleler arasındaki ilişki açısından ne ifade ettiğini açıklayınız.

45. Üç cümle arasındaki benzerlik değerleri S1-S2=0,80; S1-S3=0,25 ve S2-S3=0,60'tır. LexRank eşik değeri 0,50 olarak seçilmiştir. Grafın kenarlarını belirleyiniz, her düğümün derecesini hesaplayınız ve en yüksek dereceye sahip düğümü bulunuz.

46. Bir düğüme A ve B düğümlerinden bağlantı gelmektedir. A düğümünün skoru 0,6 ve çıkış derecesi 2; B düğümünün skoru 0,3 ve çıkış derecesi 1'dir. $S(V)=(1-d)+d\times\Sigma[S(j)/Out(j)]$ formülünde $d=0,85$ alarak bir güncelleme adımı hesaplayınız. İşlem basamaklarını gösteriniz.