II. Bölüm - Cart, Twoing, Gini, K-en Yakın Komşu (KNN) ve Ağırlık Oynama

CART Algoritması

* CART, Classification and Regression Tree ifadesinin kısaltmasıdır.
* 1984 yılında Breiman ve çalışma arkadaşları tarafından geliştirilmiştir. Temel özelliği veriyi iki gruba ayırmasıdır.
* Örneğin: bir veri kümesi yaş değişkeni üç değer alabilir:
  - Genç
  - Yaşlı
  - orta

- Cart bu değeri ikiye ayırır.

{Genç} | {Yaşlı, orta}
sol | sağ

Twoing Algoritması

* Twoing, Cart karar ağaçlarında kullanılan ikili bölümleme yöntemidir.
* Amaç; veriyi iki gruba ayırırken sınıfların mümkün olduğunca iyi ayrılmasını sağlamaktır.
* Temel kural: Twoing uygunluk değeri en yüksek olan seçilir.

$$\Phi(Bld) = 2 P_{sol} \cdot P_{sağ} \sum_{j=1}^{\hat{}} obs \left(\frac{T_{sınıf}}{B_{sol}} - \frac{T_{sınıf}}{B_{sağ}} \right)$$

Örnek:

- Tabloda çalışanların maaş, deneyim, görev niteliklerine göre hedef niteliği olan memnun olma durumlarına ait 11 gözlem verilmiştir. Twoing algoritmasını kullanarak sınıflandırma yapınız.

PERSONEL	MAAŞ	DENEYİM	GÖREV	MEMNUN
1	NORMAL	ORTA	UZMAN	EVET
2	YÜKSEK	YOK	UZMAN	EVET
3	DÜŞÜK	YOK	YÖNETİCİ	EVET
4	YÜKSEK	ORTA	YÖNETİCİ	EVET
5	DÜŞÜK	ORTA	YÖNETİCİ	EVET
6	YÜKSEK	İYİ	YÖNETİCİ	EVET
7	DÜŞÜK	İYİ	YÖNETİCİ	EVET
8	YÜKSEK	ORTA	UZMAN	HAYIR
9	DÜŞÜK	ORTA	UZMAN	HAYIR
10	YÜKSEK	İYİ	UZMAN	HAYIR
11	DÜŞÜK	İYİ	UZMAN	HAYIR

Çözüm:

	Sol	Sağ
1	Normal	{yüksek, Düşük}
2	Düşük	{Normal, yüksek}
3	yüksek	Düşük, Normal
4	yok	Orta, iyi
5	Orta	yok, iyi
6	iyi	Orta, yok
7	yönetici	Uzman
8	uzman	yönetici

	Bsol	Bsağ	Sınıf evet	Sınıf hayır	Pevet|Tsol	P hayır |Sol	Psol	Psağ
1	1	10	1	0	1	0	0.09	0.91
2	5	6	3	2	0,6	0,4	0,45	0,55
3	5	6	3	2	0,6	0,4	0,45	0,55
4	2	9	2	0	1	0	0,18	0,82
5	5	6	3	2	0,6	0,4	0,45	0,55
6	4	7	2	2	0,5	0,5	0,36	0,64
7	6	5	2	4	0,33	0,67	0,45	0,55
8	5	6	5	0	1	0	0,55	0,45

1. Durum

Psağ $\frac{10}{11} = 0.09$ $P_{evet|sol} = \frac{3}{5} = 0,6$

2. Durum

$\frac{5}{11} = P_{sol} = 0,45$ $P_{sağ} = \frac{6}{11} = 0,55$

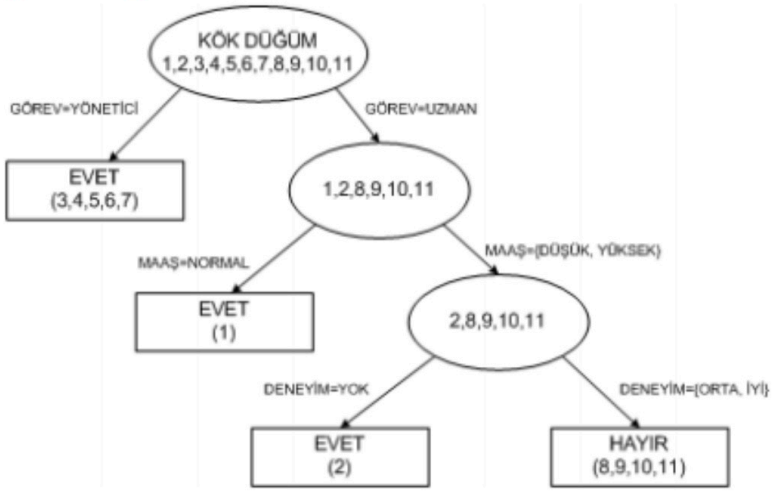
Sağa Göre

BÖLÜNME	$\|B_{sag}\|$	P_{sag}	$\|sinif_{EVET}\|$	$\|sinif_{HAYIR}\|$	$P(EVET\|t_{sag})$	$P(HAYIR\|t_{sag})$
1	10	0,91	6	4	0,6	0,4
2	6	0,55	4	2	0,67	0,33
3	6	0,55	4	2	0,67	0,33
4	9	0,82	5	4	0,56	0,44
5	6	0,55	4	2	0,67	0,33
6	7	0,64	5	2	0,71	0,29
7	5	0,45	5	0	1	0
8	6	0,55	2	4	0,33	0,67

$\Phi(1|d) = 2 \cdot 0,09 \cdot 0,91 \cdot ((1-0,6)+(1-0,4)) = 0,13$

BÖLÜNME	P_{Sol}	$P_{Sağ}$	$2P_{Sol}P_{Sağ}$	$\Phi(B\|d)$
1	0,09	0,91	0,17	0,13
2	0,45	0,55	0,5	0,07
3	0,45	0,55	0,5	0,07
4	0,18	0,82	0,3	0,26
5	0,45	0,55	0,5	0,07
6	0,36	0,64	0,46	0,2
7	0,55	0,45	0,5	0,66
8	0,45	0,55	0,5	0,66

- Sonuç karar ağacı.



Bir şirkette çalışanların memnuniyet durumları araştırılmıştır. Toplam 10 çalışan vardır.

Görev	Memnun: Evet	Memnun: Hayır	Toplam
Yönetici	4	0	4
Uzman	2	4	6
Toplam	6	4	10

Soru: Görev niteliğine göre bölünmenin Twoing uygunluk değerini hesaplayınız.

1. Adım: Sol Sağ oranlar

- Uzman sağ sol yönetici olsun:

$$P_{sol} = \frac{4}{10} \qquad P_{sağ} = \frac{6}{10}$$

2. Adım - Sınıf olasılıkları

Sol: $P(\text{Evet} \mid \text{sol}) = \frac{4}{4} = 1$

$P(\text{Hayır} \mid \text{sol}) = 0$

Sağ: $P(\text{Evet} \mid \text{sağ}) = \frac{2}{6} = 0{,}333$

$P(\text{Hayır} \mid \text{sol}) = \frac{4}{6} = 0{,}667$

3. Adım - Formüle yerleştirme

$$\Phi(B|A) = 2 \cdot P_{sağ} \cdot P_{sol} \times \sum_{j=1}^{n} \text{obs}\left(\frac{T_{sınıf}}{sol} - \frac{T_{sınıf}}{sağ}\right)$$

$= 2 \cdot 0{,}4 \cdot 0{,}6 \cdot ((1 - 0{,}333) + (0 - 0{,}667))$

$= 0{,}48 (0{,}667 + 0{,}667)$

$= 0{,}64032$

Gini Algoritması

*Gini, bir veri kümesindeki sınıfların ne kadar karmaşık olduğunu ölçen safsızlık ölçütüdür.

*Örneğin; 10 öğrenciden 10'nu başarılı ise sınıf saftır. Ancak 5 başarı 5 başarısızsa sınıflar daha karmaşıktır.

*Temel Kural: Gini değeri en küçük olan seçilir.

$$Gini(D) = 1 - \sum_{i=1}^{k} p_i^2$$

Burda p_i, ilgili sınıfın toplam veriye oranıdır.

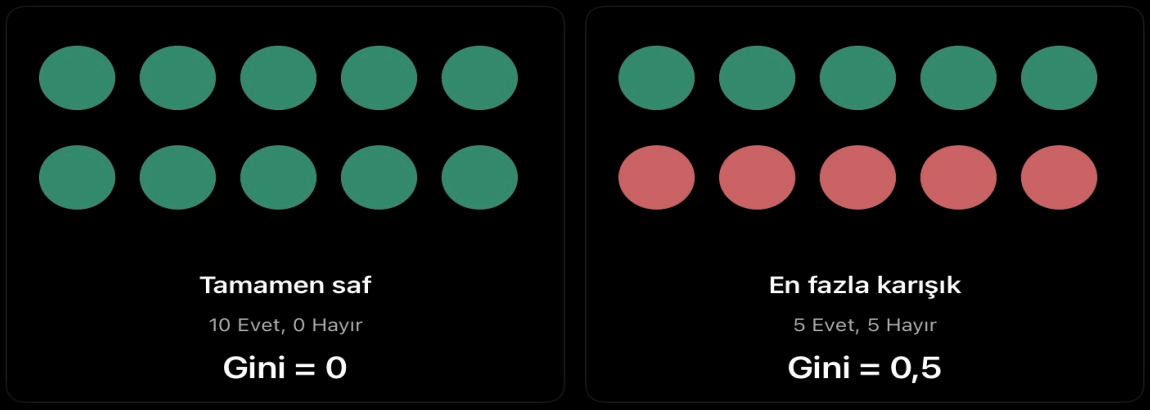
*İki sınıf varsa

$$Gini(D) = 1 - [P(evet)^2 + P(hayır)^2]$$

- İkili bölünmenin ağırlıklı gini değeri:

$$Gini_B = \frac{n_L}{n} Gini_L + \frac{n_R}{n} Gini_R$$

Burada n_L sol, n_R sağ bölümdeki örnek sayısıdır.



İki sınıflı bir problemde Gini değeri 0 ile 0,5 arasındadır. Çok sınıflı problemlerde üst sınır farklı olabilir.

Örnek: 8 gözlemden 6'sı evet 2'si hayır ise Gini değerini hesaplayınız.

1. Adım: Olasılık Hesapla

$$P(Evet) = 6/8 = 0,75$$

$$P(Hayır) = 0,25 = 2/8$$

2. Adım: Formül Hesapla

$$Gini = 1 - (0,75)^2 - (0,25)^2$$

$$= 1 - 0,5625 - 0,0625$$

$$= 0,375$$

Örnek:

Eğitim özelliğine göre:

Eğitim	Evet	Hayır	Toplam
İlk → Sol	1	2	3
Orta, Yüksek → Sağ	4	1	5

1. Adım sol Grubun ginisi:

$$Gini_{sol} = 1 - \left(\left(\frac{1}{3}\right)^2 + \left(\frac{2}{3}\right)^2\right) =$$

$$= 1 - \frac{1}{9} - \frac{4}{9} = \frac{4}{9} \approx 0,44$$

2. Adım Sağ grubun ginisi:

$$Gini_{sağ} = 1 - \left(\left(\frac{1}{5}\right)^2 - \left(\frac{4}{5}\right)^2\right)$$

$$= 1 - \frac{1}{25} - \frac{16}{25} = \frac{8}{25} = 0,32$$

3. Adım - Ağırlık Gini

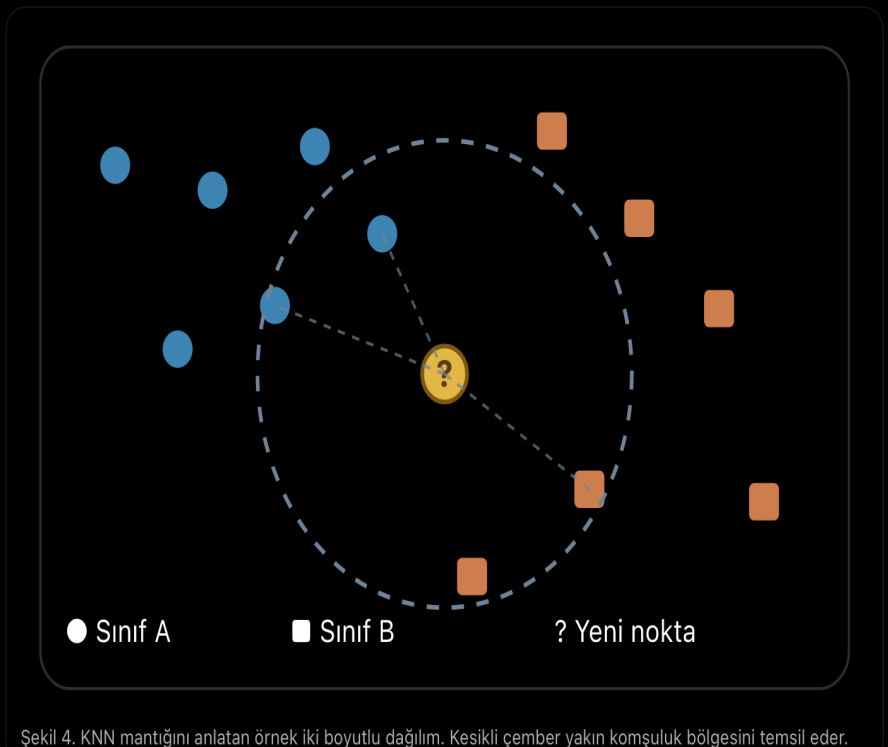
$$Gini_{Eğitim} = \frac{3}{8} \cdot (0,44) + 0.32 \cdot \frac{5}{8}$$

$$= 0,165 + 0.2$$
$$\approx 0,365$$

K-en Yakın Komşu (KNN) Algoritması

* KNN(K-Neartst Neighbors), yeni bir veri noktasının kendisine en yakın K sayıdaki gözlemin sınıfına bakarak sınıflandıran algoritmadır.
* KNN belek tabanlı bir algoritmadır.
  - K = incelenecek komşu sayısı
  - Uzaklık = Veri noktalarının birbirine yakın olduğunu gösterir.
  - Oyolama = En yakın komşular arasında en fazla bulunan sınıf seçilir.

* Çalışma mantığı:
1. K değeri seçilir.
2. Yeni noktaile eğitim kümesindeki her nokta uzaklığı hesaplanır.
3. Uzaklıklar küçükten büyüğe sıralanır
4. En yakın K gözlem seçilir.
5. Komşuların sınıfları sayılır ve çoğunluk sınıfı tahmin edilir.



Şekil 4. KNN mantığını anlatan örnek iki boyutlu dağılım. Kesikli çember yakın komşuluk bölgesini temsil eder.

$$P = (8, 4), \qquad k = 4$$

Veri kümesi:

No.	X1	X2	Sınıf
1	2	4	Kötü
2	3	6	İyi
3	3	4	İyi
4	4	10	Kötü
5	5	8	Kötü
6	6	3	İyi
7	7	9	İyi
8	9	7	Kötü
9	11	7	Kötü
10	10	2	Kötü

$d_1 = \sqrt{(2-8)^2 + (4-4)^2} = 6$

$d_2 = \sqrt{(3-8)^2 + (6-2)^2} = 5,39$

$d_3 = \sqrt{(3-8)^2 + (4-4)^2} = 5$

$d_4 = \sqrt{(4-8)^2 + (10-4)^2} = 7,21$

$d_5 = 5$

$d_6 = 2,24$ 1.

$d_7 = 5,10$

$d_8 = 3,16$ 3

$d_9 = 4,24$ 4

$d_{10} = 2,83$ 2

* (8,4) noktası genel olarak kötü olduğu için 8'e yakın sonuçlar kötü olarak sınıflandırılır.

* K değeri neden önemlidir.

* Küçük K değeri yerel örüntüde duyarlı olabilir. Büyük K değeri ise yakın çevre ayrıntılarını kaçırır.

Ağırlık oylama (weighted voting)

* Standart KNN'de seçilen komşunun bir oy hakkı vardır. Ağırlıklı KNN'de ise yakın olan komşulara daha fazla önem verilir.

$$w_i = \frac{1}{d_i^2}$$

* Bir sınıfın toplam ağırlığı:

$$W(C) = \sum_{i:y_i = C} w_i$$

Örnek:

Komşu	Uzaklık	Sınıf
1	0,44	Hayır
2	0,63	Evet
3	0,87	Evet

1. Adım - Her komşunun ağırlığını bul

$$w_1 = \frac{1}{(0{,}44)^2} = \frac{1}{0{,}1834} \cong 5{,}17$$

$$w_2 = \frac{1}{(0{,}63)^2} = \frac{1}{0{,}3363} \cong 2{,}51$$

$$w_3 = \frac{1}{(0{,}87)^2} = \frac{1}{0{,}7569} \cong 1{,}32$$

2. Adım - Toplam Ağırlık

$W(\text{Hayır}) = 5{,}17$

$W(\text{Evet}) = 1{,}32 + 2{,}51 = 3{,}83$

3. Adım - Karşılaştır

* $W(H) > W(E)$ olduğundan hayır seçilir.