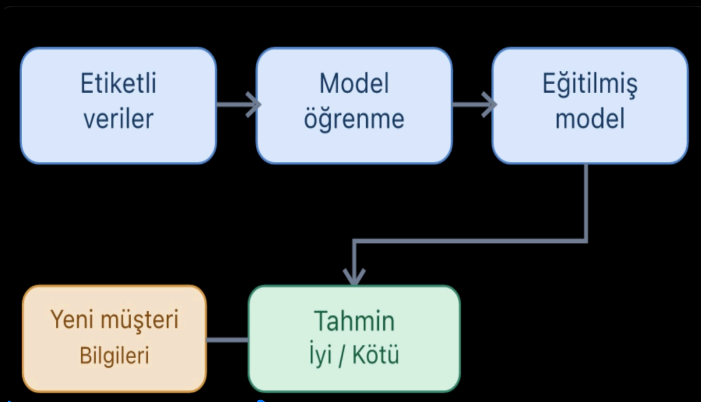
# IV. Bölüm - Sınıflandırma Yöntemleri ve Karar Ağaçlarıyla Sınıflandırma

## Sınıflandırma (Classification)

* Sınıflandırma, önceden sınıf etiketi bilinen verilerden model öğrenerek yeni verilerin hangi sınıfa ait olduğunu tahmin etme işlemidir.
* Gözetimli öğrenme (Supervised Learning) yöntemidir.

Örneğin; bir banka, müşterilerin gelirlerini, borcunu ve çalışma durumu kullanarak kredi risk analizini tahmin edebilir.

| Girdi özellikleri | Çıkış sınıfı |
|---|---|
| Gelir/borç, çalışma durumu | İyi/Kötü risk |
| E-posta içeriği | Spam / normal |
| Öğrencinin ders performansı | Başarılı / Başarısız |




### Gözetimli ve Gözetimsiz Öğrenme

| Özelik | Gözetimli (Supervised) | Gözetimsiz (Unsupervised) |
|---|---|---|
| Etiket | var | yok |
| Amaç | Sınıf ve değer tahmini | Veri içerisinde yapı keşfetme |
| Örnek | Karar ağaçları ve KNN | K-means Kümeleme |
| Uygulama | Kredi risk tahmini | Müşteri segmentasyonu |

### Sınıflandırma Süreci Aşamaları

1. Model oluşturma: Etiket eğitim verilerinden karar kurallarını öğrenmesi
2. Model değerlendirme: Eğitime katılmamış test verisiyle başarının ölçülmesi
3. Model kullanma: Daha önce görülmemiş bir örneğin sınıflandırması

* Sınıflandırma Doğruluk oranı:

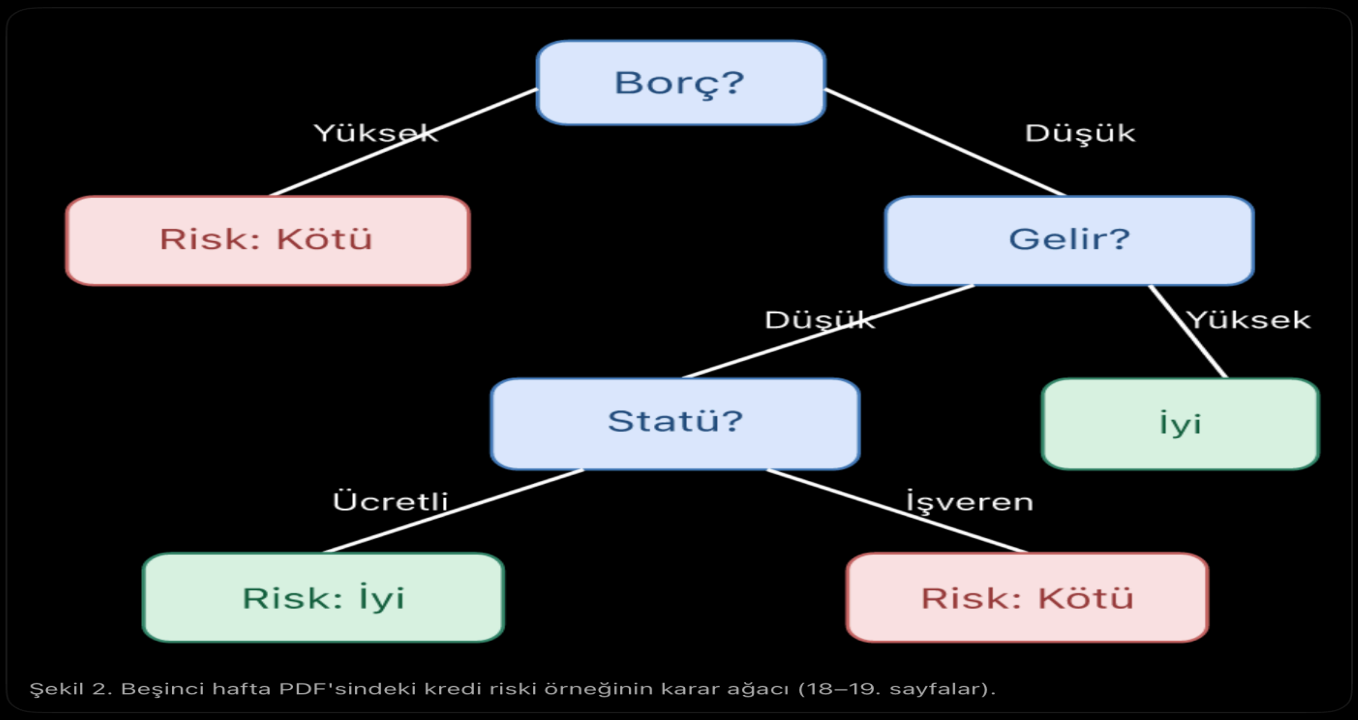
$$\text{Accuracy} = \frac{\text{Doğruluk Tahmin Sayısı}}{\text{Toplam tahmin Sayısı}}$$

## Karar Ağaçları

* Karar ağaçları, verilerin özeliklerine göre ardı ardına sınıflandırma yapan, ağaç yapısına benzeyen bir makine öğrenmesidir.

- Kök Düğüm (root): İlk sorgulanan özelik
- Karar Düğümü: Veriyi koşula göre dallandırır.
- Dal (Branch): Bir koşulun sonucudur.
- Yaprak (leaf): Son sınıf tahminidir.

## Örnek: Kredi riskini belirleme




Şekil 2. Beşinci hafta PDF'sindeki kredi riski örneğinin karar ağacı (18–19. sayfalar).

Örneğin **borcu düşük, geliri yüksek** olan bir müşteri ağacın sağ tarafındaki yolu izleyerek *Risk: İyi* sonucuna ulaşır.

## Entropi (Entropy)

* Entropi, bir veri kümesindeki belirsizliğin veya sınıf karmaşıklığı ölçüsüdür.
* Shanon Entropi:

$$H(S) = -\sum_{i=1}^{n} p_i \cdot \log_2(p_i)$$

**Örnek:** 8 müşterinin 2'si iyi 6'sı kötü skora sahip olsun. Genel entropiyi hesaplayın

$P(\text{"iyi"}) = \frac{2}{8} = 0.25$

$P(\text{"kötü"}) = \frac{6}{8} = 0.75$

$P(S) = \frac{2}{8} \cdot \log_2\left(\frac{2}{8}\right) + \frac{6}{8} \cdot \log_2 \frac{6}{8}$

$= (0.25 \cdot \frac{\log 0.25}{\log 2} + 0.75 \cdot \frac{\log 0.75}{\log 2}$

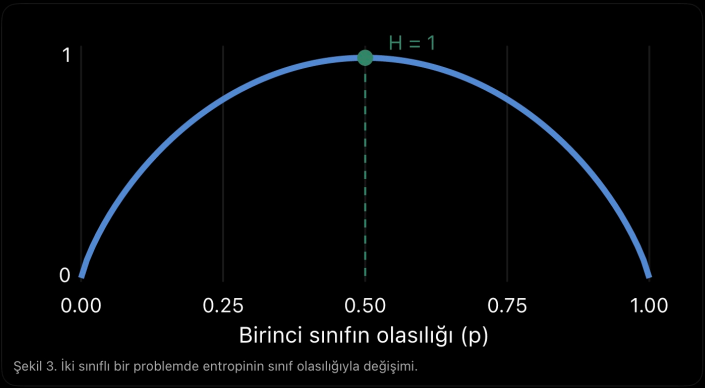
$= -(-0,5 + 0.75 \cdot -0,415$

$= -(-0,5 - 0,31125)$

$\simeq 0.81125$

⚠ virgülden sonra 3 basamak yuvarlama yapılmadı

Entropinin grafiksel yorumu




Şekil 3. İki sınıflı bir problemde entropinin sınıf olasılığıyla değişimi.

- Entropi 0: Tüm örnekler aynı sınıftadır, belirsizlik yoktur.
- Entropi 1: İki sınıf eşit olasılıktadır, belirsizlik en yüksektir.
- Entropi 0.811: Bir sınıf diğerinden daha fazla temsil edilmektedir.

## Bilgi Kazancı (Information Gain)

* Karar ağacında hangi özelliğin önce sorgulanacağını belirlemek için bilgi kazancı kullanılır.

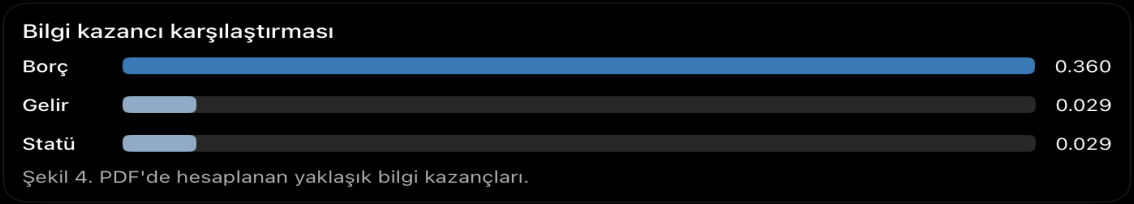
$$Gain(S, A) = H(S) - H(S|A)$$

* Burda:
  - $H(S)$ = bölünme öncesi entropi
  - $H(S|A)$ = A özelliğine göre bölündükten sonraki ağırlık

$$H(S|A) = \sum_{e} \frac{|S_e|}{|S|} H(S_e)$$

**PDF'deki kredi riski örneği**

Beşinci hafta PDF'sinin 14–17. sayfalarında 10 müşterilik veri kümesinin entropisi ve bilgi kazancı hesaplanıyor.




Şekil 4. PDF'de hesaplanan yaklaşık bilgi kazançları.

En yüksek bilgi kazancı Borç özelliğinde olduğu için karar ağacının kökünde **Borç** bulunur.

## ID3 Algoritması

* ID3 (Iterative Dichotomiser 3), entropi ve bilgi kazancını kullanarak karar ağacı oluşturan algoritmadır.

* Algoritma çalışma adımları
  1. Veri kümesinin entropisini hesapla
  2. Her özeliğin bilgi kazancını bul.
  3. En büyük bilgi kazancına sahip özeliği seç.
  4. Veri kümesini seçilen özeliğine göre böl
  5. Saf sınıf oluşana kadar işlemi tekrarla.

## C4.5 Algoritması

* C4.5 karar ağaçlarını sayısal özellikleriyle ve çalışmalarını destekleyen bir algoritmadır. Sayısal özelliklerle bölünme sağlar.

Örneğin öğrencilerin çalışma saati değerleri şu şekilde olsun:

$$X = \{2, 4, 6, 8, 10\}$$

Olası eşiklerden biri:

$$t = \frac{4 + 6}{2} = 5$$

Veriler iki gruba ayrılabilir:

- Çalışma saati ≤ 5
- Çalışma saati > 5

En uygun eşik, sınıf ayrımını iyileştiren ölçütle belirlenir.

## Çözümlü Örnek — ID3 Algoritması

**Soru:** Bir bankanın 8 müşterisine ait bilgiler aşağıdaki tabloda verilmiştir. ID3 algoritmasını kullanarak karar ağacının kök düğümünü belirleyiniz.

| Müşteri | Gelir | Borç | Kredi Riski |
|---|---|---|---|
| 1 | Yüksek | Düşük | İyi |
| 2 | Yüksek | Düşük | İyi |
| 3 | Yüksek | Yüksek | Kötü |
| 4 | Yüksek | Düşük | İyi |
| 5 | Düşük | Yüksek | Kötü |
| 6 | Düşük | Yüksek | Kötü |
| 7 | Düşük | Düşük | İyi |
| 8 | Düşük | Yüksek | Kötü |

Çözüm:

$P(\text{"iyi"}) = 0.5$

$P(\text{"kötü"}) = 0.5$

$P(S) = -\sum_{i=1}^{n} p_i \log_2(p_i)$

$P(S) = -(0.5 \cdot \underbrace{\log_2 0.5}_{-1} + 0.5 \cdot \log_2 0.5)$

$= -(0.5 \cdot -1 + -1 \cdot 0.5$

$= 1$

2. Adım = Kazanca Göre

| Gelir | Kredi |
|---|---|
| Y | İyi |
| Y | İyi |
| Y | Kötü |
| Y | İyi |
| D | Kötü |
| D | Kötü |
| D | İyi |
| D | Kötü |

$P(\text{Yüksek}) = -(0.75 \cdot \log_2 0.75 + 0.25 \cdot \log_2 0.25$

$= -(-0.311278245 + -0.5$

$= +0.811278245 \cong 0.8113$

$P(\text{"Düşük"}) = -(0.75 \cdot \log_2 0.75 + 0.25 \cdot \log_2 0.25$

$\cong 0.8113$

Ağırlık Entropisi

$P(S|G) = -(0.5 \log_2 0.8113 + 0.5 \cdot \log_2 0.8113)$

$= 0.8113$

Bilgi Kazancı:

$\text{Gain}(\text{Gelir}, \text{Kredi}) = 1 - 0.8113$

$= 0.1887$

Borç özelliği

| | Kredi |
|---|---|
| Dusuk | İyi |
| Dusuk | İyi |
| Yuksek | Kötü |
| Dusuk | İyi |
| Y | Kotu |
| Y | Kotu |
| Dusuk | İyi |
| Y | Kotu |

$P(\text{"Düşük"}) = -\left(\frac{4}{4} \log_2 \frac{4}{4}\right) = 0$

$P(\text{yüksek}) = 0$

$P(S|B) = -\left(\frac{4}{8} \log_2 0 + \frac{4}{8} \cdot \log_2 0\right) = 0$

Bilgi Kazancı:

$\text{Gain}(\text{Borç}, \text{Kredi}) = 1 - 0$

$= 1$

* Bunlardan bilgi kazancı en yüksek olan seçilir. Bu diğer dallar için geçerlidir.