I. Bölüm - Veri Madenciliğine Giriş

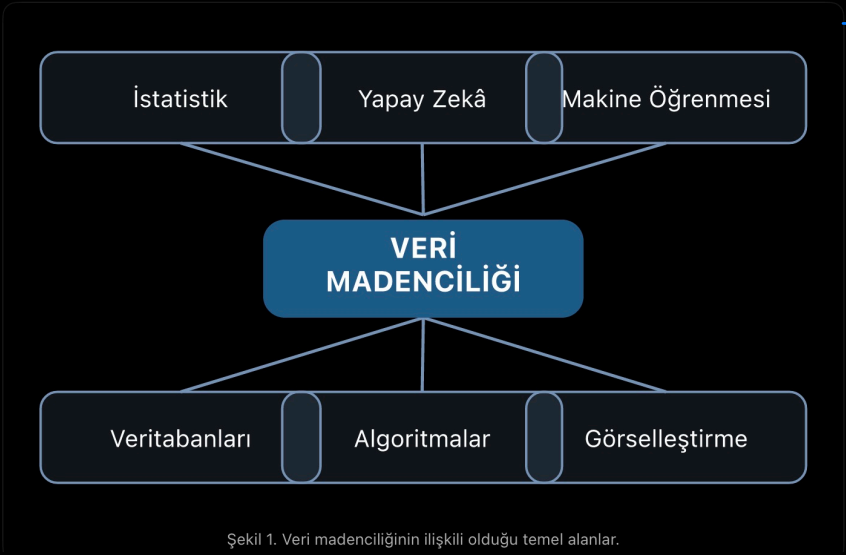
Veri Madenciliği nedir?

* Veri madenciliği, büyük miktarda veriler içerisinden daha önce bilinmeyen, anlamlı, geçerli ve kullanılabilir örüntülerin, ilişkilerin ve bilgilerin ortaya çıkarılmasıdır.
* Temel amaçları:
  - Veriler arasındaki gizli ilişkileri bulmak
  - Geçmiş verilerden yararlanarak geleceğe yönelik tahminler yapmak
  - Karar destek sistemlerine bilgi sağlamak
  - Büyük veri kümelerinden anlamlı sonuç elde etmek

Örnek: Bir markette alışveriş yapan müşterilerin alışveriş kayıtları incelendiğinde ekmek alan müşterilerin sıklıkla süt de aldığı belirlenebilir. Bu bilgi ürün yerleşiminde veya kampanyalarda kullanılabilir.

Veri madenciliği yalnızca SQL sorgusu çalıştırmak veya verileri listelemek değildir. Verilerin arasındaki anlamlı yapıları keşfetmeyi hedefler.

Veri Madenciliğinin İlişkili Olduğu Bilimler



Şekil 1. Veri madenciliğinin ilişkili olduğu temel alanlar.

* Veri madenciliği, istatistiksel analiz, makine öğrenmesi, veri tabanı teknolojileri ve görselleştirme yöntemleriyle kullanılır.

Veri Madenciliğinin Tarihsel Gelişimi

1960'lar	Veri toplama ve veri ambarı
1980'ler	Veri tabanları ve makine öğrenmesi gelişmesi
1988	Knowledge Discovery in Database (KDD) öne çıkması
1990'lar	Veri madenciliği kavramının yaygınlaşması

Bilgi Keşfi (KDD)

* Knowledge discovery in database (KDD), ham verilerin anlamlı bilgiye dönüştürülmesini sağlayan çok aşamalı süreçtir.

* Veri madenciliği, KDD sürecinin bir aşamasıdır.



Şekil 2. KDD sürecinin aşamaları. Kaynak: 1. hafta, sayfa 15–16.

ygulama örneği — Öğrenci başarısı tahmini

r üniversitede öğrencilerin başarı durumlarını tahmin etmek istediğimizi düşünelim.

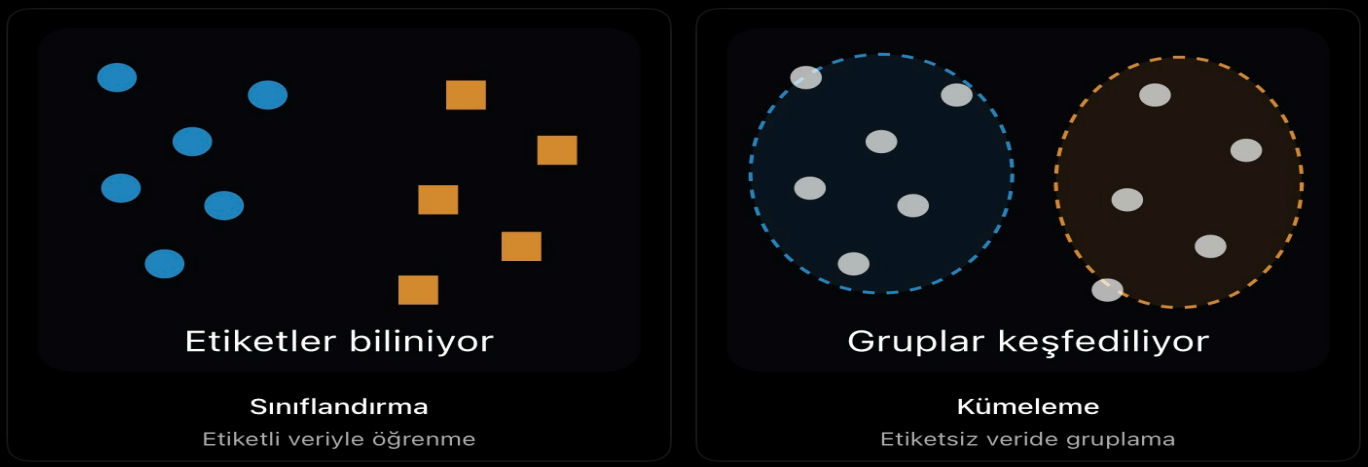
1. Öğrenci notları ve devamsızlık kayıtları toplanır.
2. Eksik notlar ve hatalı kayıtlar belirlenir.
3. Farklı sistemlerdeki öğrenci kayıtları birleştirilir.
4. Başarıyla ilişkili değişkenler seçilir.
5. Gerekli sayısal dönüşümler yapılır.
6. Bir sınıflandırma modeli eğitilir.
7. Modelin başarısı değerlendirilir.
8. Sonuçlar akademik danışmanlara raporlanır.

ırada model eğitimi veri madenciliği aşamasına, işlemlerin bütünü ise KDD recine örnektir.

Veri Madenciliği yöntemleri

Yöntem	Açıklama	Örnek
Sınıflandırma	Önceden tanımlanmış sınıfları tahmin eder.	E-postanın spam olup olmadığı
Regresyon	Sayısal değerleri tahmin eder	Ev fiyatı tahmini
Kümeleme	Benzer verileri gruplandırır.	Müşteri segmentasyonu
Birliktelik Kuralı	Birlikte görülen olayları belirler	Ekmek alanlarında süt olması
Ayrık analiz	Normalden farklı kayıtları bulur.	Şüpheli banka işlemleri

Sınıflandırma ile kümeleme arasındaki fark



Önemli: Sınıflandırma genellikle denetimli öğrenme, kümeleme ise denetimsiz öğrenme kapsamında değerlendirilir.

Veri, enformasyon, bilgi ve bilgelik

*Bu kavramlar birbiriyle ilişkili olmakla berabar aynı anlama gelmez.



Şekil 3. Bilgi piramidi — 1. hafta, sayfa 31–33.

Örnek:

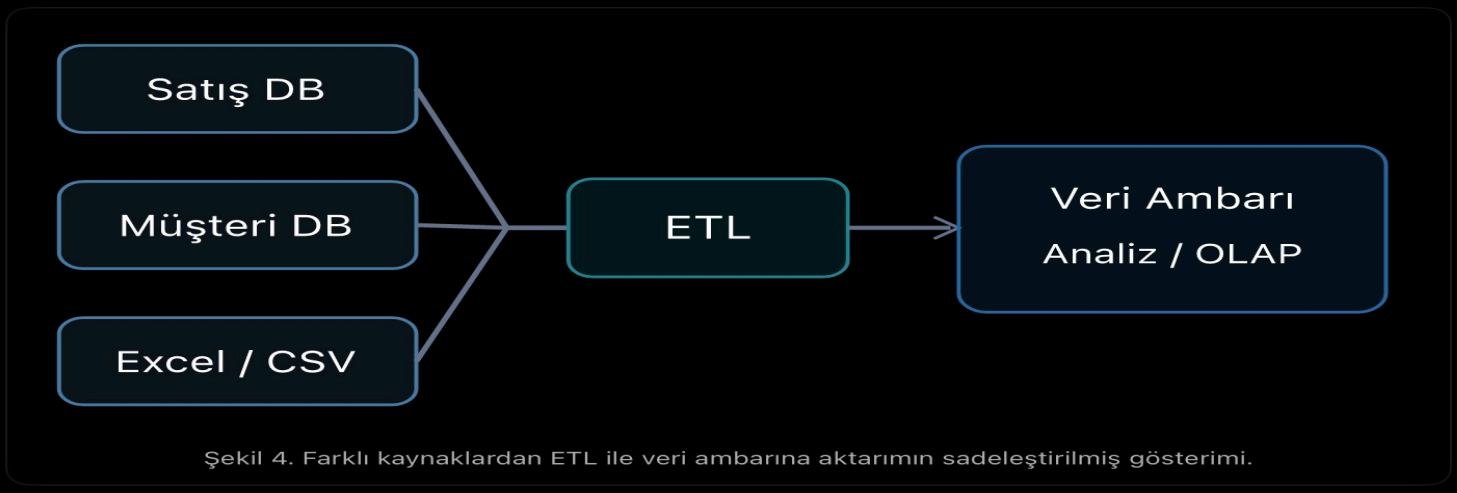
- **Veri:** Bir sınıftaki öğrencilerin sınav puanları: 45, 60, 75, 80.
- **Enformasyon:** Sınıfın puan ortalaması 65'tir.
- **Bilgi:** Bu sınıfta düşük sınav başarısının belirli konularda yoğunlaştığı anlaşılmıştır.
- **Bilgelik:** Eksik öğrenilen konular için ek çalışma planı hazırlanır.

Veri Ambarları (Data warhouse)

*Veri ambarları, farklı veri kaynaklarından toplanan bilgilerin analiz ve karar amaçlarıyla bütünleşerek saklandığı yapıdır.

*Dört temel özelliği vardır:

1. Konu odaklı: Müşteri, ürün veya satış gibi konular
2. Bütünleşik: Farklı kaynaklardan gelen verilerin ortak yapıya dönüştürür.
3. Zamana Bağlı: Tarihsel verileri saklayarak dönemsel analiz yapar.
4. Kalıcı (Non-volatile): Veriler ağırlıklı olarak sorgulama ve analiz için korur.



Şekil 4. Farklı kaynaklardan ETL ile veri ambarına aktarımın sadeleştirilmiş gösterimi.

ETL, *Extract–Transform–Load* (Çıkar–Dönüştür–Yükle) anlamına gelir.

OLTP ve OLAP karşılaştırması

OLTP	OLAP
Günlük işlemler için kullanılır	Analiz ve raporlama için kullanılır
Sık veri ekleme/güncelleme	Karmaşık analitik sorgular
Anlık operasyonel veriler	Tarihsel ve toplulaştırılmış veriler
Örnek: Sipariş oluşturma	Örnek: Yıllık satış analizi