II. Bölüm - Veri Ön İşleme - I

Veri ve nitelik kavramları

Veri (data): Nesneler ve bu nesnelerin niteliklerinden oluşan değerler bütündür.

Nesne (object): İncelenen kişi, olaylar veya kayıt

Nitelik (atribute): Bir nesneyi tanımlayan özellik

Örnek bir öğrenci veri kümesi:

Öğrenci ID	Yaş	Not	Bölüm
101	21	85	Bilgisayar
102	22	72	Elektrik
103	20	90	Bilgisayar

kayıt

nitelik

Veri Türleri

Tür	Açıklama
Norminal	Sıralama yapan kategoriler
Binary	İki olası değer
Ordinal	Sıralanabilir, farklar doğrudan ölçülmez
Interval	farklar anlamlı, gerçek sıfır yok
Ratio	Anlamlı sıfır ve oranlar vardır.

Veri Ön işleme nedir?

* Veri ön işleme, ham veriyi veri madenciliği algoritmalarına uygun, temiz, güvenilir ve kullanılabilir hale getirme sürecidir.



Ön işlemenin temel aşamaları: veriyi tanıma, veri temizleme, veri birleştirme, veri dönüşümü ve veri azaltmadır.

Kirli veri Türleri

Problem	Açıklama	Örnek
Eksik veri	Bazı değerler kaydedilmemiş	yas = null
Gürültülü veri	Ölçüm veya kayıt hatası	Sıcaklık = 800°C
Tutarsız veri	Birbirine uymayan kayıtlar	yaş = 20 doğum = 1985
Tekrarlı veri	Aynı kayıtlar birden fazla	Aynı müşteri iki kere kayıtlı

Veri tanımlama: Merkezi eğilim ölçüleri

1. Aritmatik Ortalama (Mean):

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n}$$

Örnek veri kümesi: 10, 20, 30, 40, 50

$$\bar{x} = \frac{10+20+30+40+50}{5} = 30$$

2. Ağırlık ortalama: $\bar{x}_w = \frac{\sum_{i=1}^{n} w_i x_i}{\sum_{i=1}^{n} w_i}$

Örnek: vize 70 (%40) final 80 (%60)

$$x_w = \frac{70 \cdot 0{,}4 + 80 \cdot 0{,}6}{1} = 82$$

3. Medyan (median / ortalama):

- Küçükten büyüğe sıralanmış verilerin ortasındaki değerdir.

• Tek gözlem:

10, 20, 30, 40, 50 → ortanca = 30

• Çift gözlem:

10, 20, 30, 40 → ortanca = $\frac{30+20}{1}$ = 25

4. Mod (mode / Tepe Değer)

- Veri kümesinde en çok tekrar eden değerdir.

2, 3, 3, 3, 4, 5, 6 → mod = 3

Dağılım ölçüleri

Varyans (Variance)

* Verilerin ortalamadan ne kadar uzaklaştığını ölçer.

Anakütle varyansı:

$$\sigma^2 = \frac{\sum_{i=1}^{N}(x_i - \mu)^2}{N}$$

Örneklem varyansı:

$$s^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1}$$

Çözümlü örnek: 2, 4, 6

Önce ortalamayı bulalım:

$$\bar{x} = (2+4+6)/3 = 4$$

Sapmaların kareleri:

$$(2-4)^2 = 4, \quad (4-4)^2 = 0, \quad (6-4)^2 = 4$$

Anakütle varyansı:

$$\sigma^2 = \frac{4+0+4}{3} = 2.67$$

Anakütle standart sapması:

$$\sigma = \sqrt{2.67} \approx 1.63$$

Örneklem varyansı ise $s^2 = 8/2 = 4$, örneklem standart sapması $s = 2$ olur.

Çeyreklikler ve Kutu Grafiği (Box Plot)

* Verileri dört bölüme ayıran değerler:
  - Q_1 = Birinci çeyrek (%25)
  - Q_2 = İkinci çeyrek (%50)
  - Q_3 = Üçüncü çeyrek (%75)
* Çeyrekler arası açıklık:

$$IQR = Q_3 - Q_1$$

* Aykırı değerleri belirtmek için:

$$Alt = Q_1 - 1{,}5(IQR)$$

$$Üst = Q_3 - 1{,}5(IQR)$$

Örnek: 2, 3, 4, 5, 6, 7, 8, 30

Yarıların medyanı yöntemiyle:

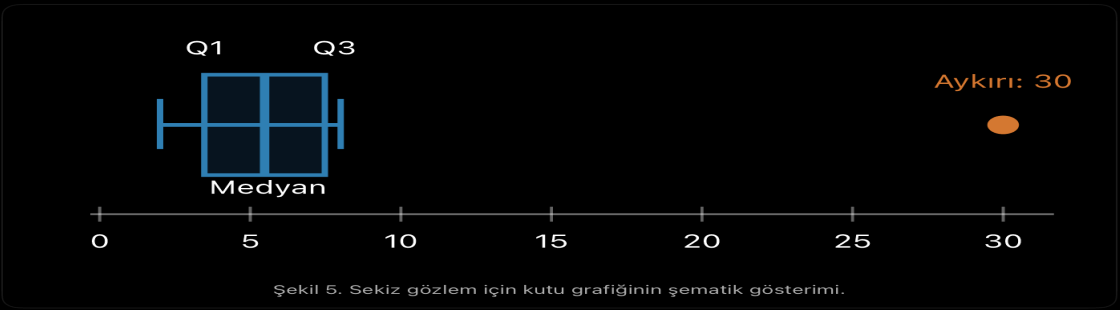
$Q_1 = 3.5, Q_2 = 5.5, Q_3 = 7.5$

$$IQR = 7.5 - 3.5 = 4$$

$$Alt = 3.5 - 6 = -2.5$$

Ust=7.5+...

30 değeri 13.5'ten büyük olduğu için aykırı değer adayıdır.



Şekil 5. Sekiz gözlem için kutu grafiğinin şematik gösterimi.

Aykırı değer her zaman hatalı veri değildir. Gerçek ve önemli bir gözlem de olabilir. Silmeden önce nedeni incelenmelidir.

Eksik veri ve tamamlama yöntemleri

* Eksik veri ölçüm yapılamaması, kayıt hatası, sistem arızası veya bilginin bilinmemesiyle oluşur.
* Başlıca yöntemler:
  - Eksik kayıtları analiz dışında bırakma
  - Veriyi elle doldurma
  - Bilinmiyor gibi özel değer kullanma
  - Ortalama, medyan ve mod ile doldurma
  - Aynı sınıftaki kayıtları kullanarak doldurma
  - Tahmin yöntemiyle doldurma

Çözümlü örnek — Ortalama ile doldurma

Öğrenci	Not
A	60
B	70
C	Eksik
D	80

$$\bar{x} = \frac{60 + 70 + 80}{3} = 70$$

C öğrencisinin eksik notu örnek amaçlı 70 ile doldurulur.

Ancak bu işlem yalnızca bir ön işleme yöntemidir. Gerçek sınav sonucunun 70 olduğunu göstermez. Uygun yöntem verinin özelliğine göre seçilmelidir.

2.9. Gürültülü verinin temizlenmesi

Ders notlarında gürültüyü azaltmak için üç temel yaklaşım ele alınır:

Bölmeleme (Binning): Sıralanmış değerler gruplara ayrılır ve grup içindeki değerler, ortalama veya sınırlara göre düzeltilir.

Kümeleme: Birbirine benzeyen değerler aynı kümeye alınır; uzak veya olağandışı kayıtlar incelenir.

Eğri uydurma (Regression): Veriye uygun fonksiyon belirlenir ve sapmalar analiz edilir.

Çözümlü bölmeleme örneği

Veri: 4, 8, 15, 21, 24, 25

Üçer elemanlı iki kutuya ayıralım:

Kutu	Değerler	Ortalama
1	4, 8, 15	9
2	21, 24, 25	23.33

Ortalama ile yumuşatma sonrasında:

$$[9, 9, 9, 23.33, 23.33, 23.33]$$

Bölmeleme yönteminin amacı küçük dalgalanmaları azaltmaktır. Ancak veri içerisindeki ayrıntıların bir kısmı kaybolabilir.

2.10. Veri birleştirme (Data Integration)

Farklı kaynaklarda bulunan kayıtların ortak bir veri kümesinde bütünleştirilmesidir.

Örnek: Bir üniversitede öğrenci bilgileri PostgreSQL veritabanında, sınav sonuçları ise Excel dosyalarında tutulabilir. Ortak öğrenci ID'si kullanılarak iki kaynak birleştirilebilir.

Bu aşamada karşılaşılabilecek problemler:

- Farklı sütun isimleri (`ogrenci_no`, `student_id`)
- Farklı veri tipleri
- Aynı kişinin birden fazla kaydı
- Farklı ölçü birimleri
- Birbiriyle çelişen değerler