III. Bölüm - Veri Ön İşleme - II

Veri Dönüşümü (Data Transmition)

* Veri dönüşümü, veri kümelerindeki değerlerin algoritmalar tarafından daha uygun şekilde kullanılabilmesini sağlamak amacıyla değiştirilmesidir.

* Başlıca işlemler:
  - Veri düzenleme
  - Birleştirme
  - Genelleme
  - Normalizasyon
  - Nitelik oluşturma

Normalizasyon Yöntemleri

* Normalizasyon, farklı ölçeklerdeki sayısal değerlerin karşılaştırılabilir hale gelmesi amaçlanır.

A- Min-max Normalizasyonu

- Değerler belirlenen yeni aralığa doğrusal olarak dönüşür.
- Genel formül:

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}} (b-a) + a$$

Burada $[a, b]$ hedef aralıktır.

0–1 aralığı için:

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

Çözümlü örnek: Bir sınavın en düşük notu 20, en yüksek notu 100 olsun. 60 alan öğrencinin normalleştirilmiş notu:

$$x' = \frac{60 - 20}{100 - 20} = \frac{40}{80} = 0.5$$



Şekil 6. Min-Max normalizasyonunda ölçek değişir, değerlerin sıralaması korunur.

Z-Score Normalizasyonu

- Verileri ortalama ve standart sapma üzerinden dönüştür.

$$z = \frac{x - \mu \rightarrow \text{ortalama}}{\sigma \rightarrow \text{standart sapma}}$$

Çözümlü örnek: Ortalama 70, standart sapma 10, öğrencinin notu 85 olsun.

$$z = \frac{85 - 70}{10} = 1.5$$

Bu öğrencinin notu ortalamanın 1.5 standart sapma üzerindedir.

Z-score yöntemi verileri belirli bir 0–1 aralığına sıkıştırmaz. Kullanılan ortalama ve standart sapmaya bağlı olarak merkezleme ve ölçekleme yapar.

C. Ondalık normalizasyon

Değerler uygun bir 10 kuvvetine bölünür.

$$x' = \frac{x}{10^j}$$

Burada j, dönüştürülmüş en büyük mutlak değeri 1'den küçük yapacak en küçük negatif olmayan tam sayıdır.

Örnek: 25, 300, 900 değerleri için $j = 3$.

$$25' = 0.025, \quad 300' = 0.3, \quad 900' = 0.9$$

Nitelik Oluşturma (Feature Construction)

* Mevcut niteliklerden yeni ve daha anlamlı özellikler üretme işlemidir.

Örnek: Bir binanın genişliği ve uzunluğu biliniyorsa:

Alan = Genişlik x Uzunluk

Genişlik = 10

Uzunluk = 20

Alan = 200

Veri Azaltma (Data Reduction)

* Veri azaltma, veri kümesinin temsil ettiği önemli bilgiyi mümkün olduğunca koruyarak boyutunun veya hacmin küçültülmesidir.

* Başlıca Yöntemler:

- Nitelik birleştirme
- Nitelik seçme ve hizalama
- Veri sıkıştırma
- Veri ayrıştırma ve kavram oluşturma
- Histogram, kümeleme ve örnekleme

Nitelik Seçimi – Boyut azaltma

* Nitelik seçilimi: mevcut niteliklerden yararlı olanların alt kümesini seçmesidir.
* Boyut Azaltma: veriyi daha küçük boyutlu gösterime dönüştürür.

Örnek:



Şekil 7. Altı nitelikten üç nitelik seçilmesi — 3. hafta, sayfa 13'teki örneğin sadeleştirilmiş hâli.

Nitelik seçme yöntemleri arasında istatistiksel anlamlılık testleri, bilgi kazancı ve karar ağaçlarına dayalı yaklaşımlar bulunur.

Boyut azaltmada ise:

$$d \text{ boyutlu veri} \longrightarrow k \text{ boyutlu veri}, \quad k < d$$

Örneğin 100 değişkenli bir veri kümesi, uygun bir yöntemle 10 yeni bileşen kullanılarak temsil edilebilir.

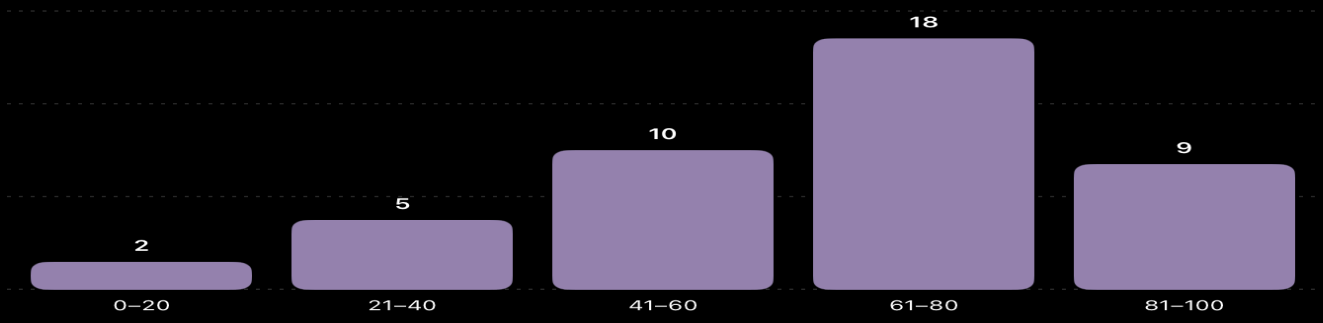
3.7. Veri sıkıştırma ve veri küçültme

Kayıpsız sıkıştırma: Orijinal veri tamamen geri elde edilebilir.

Kayıplı sıkıştırma: Daha fazla küçültme karşılığında bazı ayrıntılar kaybolabilir.

Histogram ile küçültme: Sayısal değerler aralıklara ayrılarak frekanslarıyla temsil edilir.

Not aralıklarına göre öğrenci sayısı
Histogramın temsili bir örneği



Bu gösterim 44 öğrencinin notlarını tek tek sunmak yerine notların dağılımını beş aralıkta özetler.

Kümeleme ile küçültme: Veri, benzer örneklerden oluşan kümelere ayrılarak küme merkezleri gibi temsilcilerle özetlenebilir.

Örnekleme (Sampling): Büyük veri kümesini temsil edecek daha küçük bir alt küme seçilir.

Örnek olarak 100.000 satırdan 10.000 satır seçilmesi işlem yükünü azaltabilir. Ancak örneklemin temsil gücü kontrol edilmelidir.

3.8. Benzerlik ve farklılık ölçüleri

Benzerlik ve uzaklık ölçüleri, iki nesnenin birbirine ne kadar benzediğini veya farklı olduğunu belirler.

Uzaklık değeri küçüldükçe nesneler genellikle birbirine daha yakındır.

A. Öklid uzaklığı (Euclidean Distance)

İki nokta arasındaki doğrusal uzaklıktır.

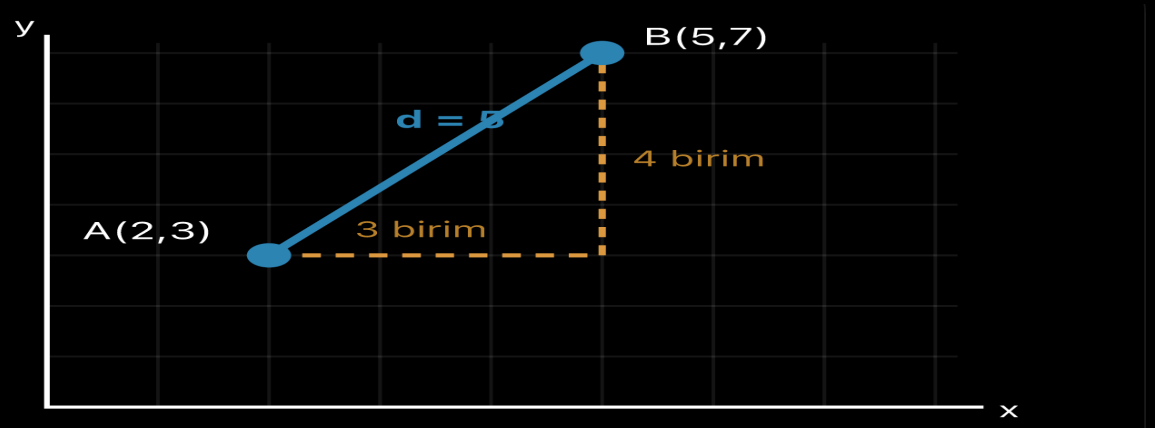
$$d(x, y) = \sqrt{\sum_{i=1}^{n} (x_i - y_i)^2}$$

Çözümlü örnek:

A = (2, 3), B = (5, 7)

$$d(A, B) = \sqrt{(5-2)^2 + (7-3)^2}$$

$$= \sqrt{9 + 16} = \sqrt{25} = 5$$



Şekil 8. Öklid uzaklığı ve 3–4–5 dik üçgeni.

B. Manhattan uzaklığı

Koordinatlar arasındaki mutlak farkların toplamıdır.

$$d(x, y) = \sum_{i=1}^{n} |x_i - y_i|$$

A = (2, 3), B = (5, 7):

$$d(A, B) = |5-2| + |7-3| = 3 + 4 = 7$$

Manhattan uzaklığı, kareli bir şehir planında yatay ve dikey yollarla ilerleme benzetmesiyle açıklanabilir.

C. Minkowski uzaklığı

Öklid ve Manhattan uzaklıklarını genelleştiren ölçüdür.

$$d_p(x, y) = \left(\sum_{i=1}^{n} |x_i - y_i|^p \right)^{1/p}$$

- $p = 1$: Manhattan uzaklığı
- $p = 2$: Öklid uzaklığı

3.9. Uzaklık ölçülerinin özellikleri

Bir metrik uzaklık fonksiyonu şu özellikleri sağlamalıdır:

1. **Negatif olmama:** $d(x, y) \geq 0$
2. **Özdeşlik:** $d(x, y) = 0$ ancak ve ancak $x = y$
3. **Simetri:** $d(x, y) = d(y, x)$
4. **Üçgen eşitsizliği:** $d(x, z) \leq d(x, y) + d(y, z)$

Bu özellikler, özellikle kümeleme ve en yakın komşu algoritmalarında önemlidir.

3.10. İkili değişkenler arasında benzerlik

İkili (binary) nitelikler 0 veya 1 değerini alır.

İki nesne karşılaştırılırken:

	B = 0	B = 1
A = 0	M_{00}	M_{01}
A = 1	M_{10}	M_{11}

Basit eşleşme katsayısı

$$SMC = \frac{M_{00} + M_{11}}{M_{00} + M_{01} + M_{10} + M_{11}}$$

Hem 0–0 hem de 1–1 eşleşmelerini dikkate alır.

Jaccard benzerliği

$$J(A, B) = \frac{M_{11}}{M_{01} + M_{10} + M_{11}}$$

Ortak 0–0 durumlarını benzerlik hesabına katmaz.

Çözümlü örnek:

A = [1, 1, 0, 0, 1]

B = [1, 0, 0, 1, 1]

Burada:

$$M_{11} = 2, \quad M_{00} = 1$$

$$M_{10} = 1, \quad M_{01} = 1$$

$$M_{11} = 2, \quad M_{00} = 1$$

$$M_{10} = 1, \quad M_{01} = 1$$

Basit eşleşme katsayısı:

$$SMC = \frac{2 + 1}{5} = 0.6$$

Jaccard benzerliği:

$$J = \frac{2}{2 + 1 + 1} = 0.5$$

Jaccard, örneğin bir belgede belirli kelimelerin bulunup bulunmaması gibi asimetrik ikili özelliklerde yararlıdır.

3.11. Kosinüs benzerliği (Cosine Similarity)

Kosinüs benzerliği, iki vektörün yönleri arasındaki benzerliği ölçer.

$$\cos(\theta) = \frac{A \cdot B}{\|A\| \|B\|}$$

Burada:

- $A \cdot B$: Vektörlerin skaler çarpımı
- $\|A\|$: A vektörünün uzunluğu
- $\|B\|$: B vektörünün uzunluğu

Çözümlü örnek:

A = (1, 2), B = (2, 4)

Skaler çarpım:

$$A \cdot B = 1(2) + 2(4) = 10$$

Vektör uzunlukları:

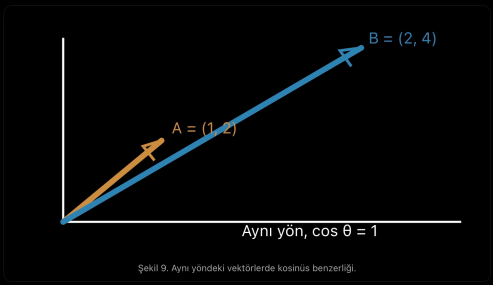
$$\|A\| = \sqrt{1^2 + 2^2} = \sqrt{5}$$

$$\|B\| = \sqrt{2^2 + 4^2} = \sqrt{20}$$

Sonuç:

$$\cos(\theta) = \frac{10}{\sqrt{5}\sqrt{20}} = 1$$

Kosinüs benzerliğinin 1 olması, iki vektörün aynı yönde olduğunu gösterir. Sıfır olmayan pozitif bileşenli vektörlerde benzerlik genellikle 0 ile 1 arasındadır; genel durumda -1 ile 1 arasında olabilir.



Şekil 9. Aynı yöndeki vektörlerde kosinüs benzerliği.

Kosinüs benzerliği özellikle metin madenciliği, TF-IDF belge vektörleri ve doküman benzerliği hesaplamalarında kullanılır.