VERİ MADENCİLİĞİ
Ayrıntılı Çözümlü Cevap Anahtarı

Hafta 4-7 - formüller, ara değerler ve nihai sonuçlar

Bu dosya, ayrı soru kitapçığındaki 10 hesaplamalı sorunun çözümüdür. Entropi ve bilgi kazancı sonuçları log_2 ile; uzaklıklar aksi belirtilmedikçe Öklid metriğiyle hesaplanmıştır. Yuvarlama farkları için 3 ondalık basamak kabul edilebilir.

Kapsam	Sorular
Entropi, bilgi kazancı, ID3-C4.5	1-3
CART Twoing ve Gini	4-5
Uzaklıklar ve k-NN	6-7
Tek/tam bağlantı ve K-Means	8-10

Soru 1 - Entropi hesabı - çözüm (6 puan)

Toplam 14 kayıt vardır: Normal = 9, Şüpheli = 5.

p(Normal) = 9/14 = 0,642857
p(Şüpheli) = 5/14 = 0,357143

```
H(S) = -[(9/14)log_2(9/14) + (5/14)log_2(5/14)]
```

Sınıf	p	log_2(p)	-p log_2(p)
Normal	0,642857	-0,637430	0,409776
Şüpheli	0,357143	-1,485427	0,530658

H(S) = 0,409776 + 0,530658 = 0,940434 bit

Soru 2 - ID3 ile bilgi kazancı - çözüm (12 puan)

Hedef dağılımı: Onay = 6, Red = 4.

```
H(S) = -[0,6 log_2(0,6) + 0,4 log_2(0,4)] = 0,970951
```

1) Borç niteliği

Borç	Onay	Red	Entropi	Ağırlık
Düşük	4	1	H(4/5,1/5)=0,721928	5/10
Yüksek	2	3	H(2/5,3/5)=0,970951	5/10

H(S|Borç) = (5/10)(0,721928) + (5/10)(0,970951) = 0,846439
Kazanç(Borç) = 0,970951 - 0,846439 = 0,124511

2) Gelir niteliği

Gelir	Onay	Red	Entropi	Ağırlık
Yüksek	5	0	H(5/5,0/5)=0	5/10
Düşük	1	4	H(1/5,4/5)=0,721928	5/10

H(S|Gelir) = (5/10)(0) + (5/10)(0,721928) = 0,360964
Kazanç(Gelir) = 0,970951 - 0,360964 = 0,609987

0,609987 > 0,124511 olduğundan ID3 kök düğümde Gelir niteliğini seçer.

Soru 3 - C4.5 sayısal eşik seçimi - çözüm (10 puan)

Toplam Onay = 5, Red = 3 olduğundan:

```
H(S) = -[(5/8)log_2(5/8) + (3/8)log_2(3/8)] = 0,954434
```

Eşik t	Sol (≤t)	H_sol	Sağ (>t)	H_sağ	H_ağırlıklı	Kazanç
51,5	0 O / 2 R	0	5 O / 1 R	0,650022	(2/8)0+(6/8)0,650022=0,487517	0,466917
58,0	1 O / 2 R	0,918296	4 O / 1 R	0,721928	(3/8)0,918296+(5/8)0,721928=0,795566	0,158868
64,5	1 O / 3 R	0,811278	4 O / 0 R	0	(4/8)0,811278+(4/8)0=0,405639	0,548795

En büyük bilgi kazancı 0,548795'tir. Seçilen eşik t = 64,5; dallar Puan ≤ 64,5 ve Puan > 64,5 olur.

Soru 4 - CART Twoing uygunluk değeri - çözüm (10 puan)

İki sınıf için her adayda önce P_L=n_L/12 ve P_R=n_R/12 bulunur. Sonra sol ve sağ sınıf oranlarının mutlak farkları toplanır.

A adayı

P_L=5/12, P_R=7/12; sol=(4/5,1/5), sağ=(2/7,5/7)
Σ fark = |4/5-2/7| + |1/5-5/7| = 18/35 + 18/35 = 36/35
Φ_A = 2(5/12)(7/12)(36/35) = 0,500000

B adayı

P_L=P_R=6/12; sol=(5/6,1/6), sağ=(1/6,5/6)
Σ fark = |5/6-1/6| + |1/6-5/6| = 4/6 + 4/6 = 4/3
Φ_B = 2(1/2)(1/2)(4/3) = 0,666667

C adayı

P_L=4/12, P_R=8/12; sol=(3/4,1/4), sağ=(3/8,5/8)
Σ fark = |3/4-3/8| + |1/4-5/8| = 3/8 + 3/8 = 3/4
Φ_C = 2(1/3)(2/3)(3/4) = 0,333333

Aday	Φ
A	0,500
B	0,667
C	0,333

En yüksek Twoing uygunluğu B adayındadır; CART bu düğümde B bölmesini seçer.

Soru 5 - CART Gini ile bölme seçimi - çözüm (10 puan)

Her alt grup için Gini = 1 - [p(Onay)^2 + p(Red)^2].

Gelir

Sol (5/0): Gini_L=1-(1^2+0^2)=0
Sağ (1/4): Gini_R=1-[(1/5)^2+(4/5)^2]=0,32
Gini_Gelir=(5/10)0+(5/10)0,32=0,160000

Yaş

Sol (2/2): Gini_L=1-[(2/4)^2+(2/4)^2]=0,50
Sağ (4/2): Gini_R=1-[(4/6)^2+(2/6)^2]=4/9=0,444444
Gini_Yaş=(4/10)0,50+(6/10)0,444444=0,466667

Borç

Sol (5/1): Gini_L=1-[(5/6)^2+(1/6)^2]=10/36=0,277778
Sağ (1/3): Gini_R=1-[(1/4)^2+(3/4)^2]=6/16=0,375
Gini_Borç=(6/10)0,277778+(4/10)0,375=0,316667

Aday	Ağırlıklı Gini
Gelir	0,160000
Yaş	0,466667
Borç	0,316667

En küçük ağırlıklı Gini 0,16 olduğundan ilk bölme Gelir niteliğine göre yapılır.

Soru 6 - Uzaklıklar - çözüm (8 puan)

Koordinat farklarının mutlak değerleri: |2-7|=5, |-1-3|=4, |4-1|=3.

Öklid

d_E = √(5^2+4^2+3^2) = √(25+16+9) = √50 = 7,071068

Manhattan

d_M = 5+4+3 = 12

Minkowski, p=3

d_3 = (5^3+4^3+3^3)^(1/3) = (125+64+27)^(1/3) = 216^(1/3) = 6

Sonuçlar: Öklid = 7,071; Manhattan = 12; Minkowski(p=3) = 6.

Soru 7 - Min-max normalleştirmeli k-NN - çözüm (10 puan)

X1 için payda 20-10=10; X2 için payda 100-20=80'dir. Q=(16,50) → Q'=(6/10,30/80)=(0,600;0,375).

Kayıt	Normalize (X1', X2')	Q'ya Öklid uzaklığı	Sınıf	Sıra
A	(0,000;1,000)	√[(0-0,6)^2+(1-0,375)^2]=0,866386	Evet	5
B	(0,200;0,875)	√[(-0,4)^2+(0,5)^2]=0,640312	Evet	4
C	(0,800;0,250)	√[(0,2)^2+(-0,125)^2]=0,235850	Hayır	1
D	(1,000;0,000)	√[(0,4)^2+(-0,375)^2]=0,548293	Hayır	3
E	(0,400;0,500)	√[(-0,2)^2+(0,125)^2]=0,235850	Evet	2

En yakın üç kayıt: C (Hayır), E (Evet), D (Hayır). Oylar Hayır=2, Evet=1.

k=3 çoğunluk oylamasıyla Q noktasının tahmin edilen sınıfı Hayırdır.

Soru 8 - Tek bağlantı - çözüm (10 puan)

Çiftler arası Öklid uzaklıkları aşağıdadır. Örneğin d(P1,P4)=√[(1-6)^2+(1-5)^2]=√41=6,403.

	P1	P2	P3	P4	P5
P1	0	1,414	5,000	6,403	8,000
P2	1,414	0	4,243	5,000	7,071
P3	5,000	4,243	0	1,414	5,000
P4	6,403	5,000	1,414	0	5,000
P5	8,000	7,071	5,000	5,000	0

Birleşme 1 ve 2

En küçük değer 1,414'tür ve iki eşit çift vardır: {P1,P2} ile {P3,P4} aynı yükseklikte oluşturulur.

Kalan kümeler: A={P1,P2}, B={P3,P4}, C={P5}.
d_tek(A,B)=min(5,000;6,403;4,243;5,000)=4,243
d_tek(B,C)=min(5,000;5,000)=5,000
d_tek(A,C)=min(8,000;7,071)=7,071

Birleşme 3

A ve B, 4,243 uzaklığında birleşir: {P1,P2,P3,P4}.

Birleşme 4

Yeni kümenin P5'e tek bağlantı uzaklığı min(8,000;7,071;5,000;5,000)=5,000'dir. Son birleşme 5,000'te gerçekleşir.

Adım	Birleşen kümeler	Uzaklık
1	{P1}+{P2}	1,414
2	{P3}+{P4}	1,414
3	{P1,P2}+{P3,P4}	4,243
4	{P1,P2,P3,P4}+{P5}	5,000

Tek bağlantı birleşme yükseklikleri: 1,414; 1,414; 4,243; 5,000.

Soru 9 - Tam bağlantı - çözüm (8 puan)

Başlangıç uzaklık matrisi Soru 8 ile aynıdır. İlk iki eşit birleşme yine {P1,P2} ve {P3,P4} çiftleridir; her ikisi de 1,414 uzaklığındadır.

A={P1,P2}, B={P3,P4}, C={P5} için tam bağlantı uzaklıkları:

```
d_tam(A,B)=max(5,000;6,403;4,243;5,000)=6,403
d_tam(B,C)=max(5,000;5,000)=5,000
d_tam(A,C)=max(8,000;7,071)=8,000
```

B ile C en küçük tam bağlantı değeri olan 5,000'te birleşir: {P3,P4,P5}. Sonra A ile bu küme arasındaki tam bağlantı uzaklığı, çapraz uzaklıkların en büyüğü olan d(P1,P5)=8,000'dir.

Adım	Birleşen kümeler	Uzaklık
1	{P1}+{P2}	1,414
2	{P3}+{P4}	1,414
3	{P3,P4}+{P5}	5,000
4	{P1,P2}+{P3,P4,P5}	8,000

Tam bağlantı birleşme yükseklikleri: 1,414; 1,414; 5,000; 8,000.

Soru 10 - K-Means iterasyonları - çözüm (16 puan)

Başlangıç: M1^(0)=(1,1), M2^(0)=(2,1).

1. atama

Nokta	d(M1^(0))	d(M2^(0))	Küme
A(1,1)	0	1,000	C1
B(1,2)	1,000	1,414	C1
C(2,1)	1,000	0	C2
D(8,8)	9,899	9,220	C2
E(9,8)	10,630	9,899	C2
F(8,9)	10,630	10,000	C2

C1={A,B}; C2={C,D,E,F}. Yeni merkezler:
M1^(1)=((1+1)/2,(1+2)/2)=(1;1,5)
M2^(1)=((2+8+9+8)/4,(1+8+8+9)/4)=(6,75;6,5)

Bu merkezlere göre E^2_1 = 0,25+0,25 = 0,50.
E^2_2 = 52,8125+3,8125+7,3125+7,8125 = 71,75.
Toplam E^2 = 72,25.

2. atama

Nokta	d(M1^(1))	d(M2^(1))	Yeni küme
A	0,500	7,956	C1
B	0,500	7,250	C1
C	1,118	7,314	C1 (değişti)
D	9,552	1,953	C2
E	10,260	2,704	C2
F	10,260	2,795	C2

Yeni üyelikler: C1={A,B,C}; C2={D,E,F}.
M1^(2)=((1+1+2)/3,(1+2+1)/3)=(4/3;4/3)=(1,333;1,333)
M2^(2)=((8+9+8)/3,(8+8+9)/3)=(25/3;25/3)=(8,333;8,333)

Yeni merkezlere göre her kümenin kare-hatası 12/9=4/3'tür:
E^2 = 4/3 + 4/3 = 8/3 = 2,666667.

3. kontrol

M1^(2) ve M2^(2) kullanıldığında A,B,C yine C1'e; D,E,F yine C2'ye atanır. Üyelik değişmediği için algoritma durur.

Nihai sonuç: C1={A,B,C}, merkezi (1,333;1,333); C2={D,E,F}, merkezi (8,333;8,333); toplam kare-hata E^2=2,667.