VERİ MADENCİLİĞİ
Hesaplamalı Vize Çalışma Kitapçığı

Hafta 4-7 ders notlarına dayalı - yalnızca sayısal klasik sorular

Ad Soyad: .....

Tarih: ..... Süre hedefi: 120 dakika Toplam: 100 puan

Uygulama bilgileri

• Tüm işlemleri gösteriniz. Sonucu uygun sayıda ondalık basamakla yazınız.
• Entropi ve bilgi kazancı hesaplarında log_2 kullanınız.
• Uzaklık ve kümeleme sorularında ara uzaklıkları tabloya veya işlem alanına yazınız.
• Sorular; entropi/bilgi kazancı, ID3-C4.5, CART Twoing-Gini, uzaklıklar, k-NN, hiyerarşik kümeleme ve K-Means hesaplarından oluşur.

Not: Bu kitapçıkta teori açıklaması veya çoktan seçmeli soru yoktur. Her soruda gerekli veri ve hesap tanımı verilmiştir.

Soru 1 - Entropi hesabı (6 puan)

Bir dolandırıcılık taramasında 14 işlemin 9'u Normal, 5'i Şüpheli olarak etiketlenmiştir. Veri kümesinin sınıf entropisini hesaplayınız.

```
Kullanınız: H(S) = -Σ p_i log_2(p_i)
```

İşlem ve cevap alanı

Soru 2 - ID3 ile bilgi kazancı (12 puan)

Aşağıdaki 10 kayıt için önce hedef sınıfın entropisini hesaplayınız. Ardından Borç ve Gelir niteliklerinin ağırlıklı bölünme entropilerini ve bilgi kazançlarını bulunuz. ID3'e göre kök düğümde kullanılacak niteliği belirleyiniz.

Kayıt	Borç	Gelir	Kredi sonucu
1	Düşük	Yüksek	Onay
2	Düşük	Yüksek	Onay
3	Düşük	Düşük	Onay
4	Düşük	Düşük	Red
5	Düşük	Yüksek	Onay
6	Yüksek	Yüksek	Onay
7	Yüksek	Yüksek	Onay
8	Yüksek	Düşük	Red
9	Yüksek	Düşük	Red
10	Yüksek	Düşük	Red

```
Kazanç(A,S) = H(S) - Σ_v (|S_v|/|S|) H(S_v)
```

İşlem ve cevap alanı

Soru 3 - C4.5 sayısal eşik seçimi (10 puan)

Bir başvurunun tek sayısal niteliği Puandır. Aşağıdaki sıralı veride aday eşikler t = 51,5; 58,0 ve 64,5 olarak verilmiştir. Her aday için Puan ≤ t ve Puan > t biçiminde iki grup oluşturunuz; ağırlıklı entropiyi ve bilgi kazancını hesaplayınız. En yüksek kazançlı eşiği seçiniz.

Puan	42	48	55	61	68	72	79	85
Sonuç	Red	Red	Onay	Red	Onay	Onay	Onay	Onay

```
Kazanç(t) = H(S) - [ (|S_sol|/|S|)H(S_sol) + (|S_sağ|/|S|)H(S_sağ) ]
```

İşlem ve cevap alanı

Soru 4 - CART Twoing uygunluk değeri (10 puan)

12 müşterinin hedef sınıfı Evet/Hayır'dır. Üç aday ikili bölme için sınıf dağılımları aşağıdadır. Her adayın Twoing uygunluk değerini hesaplayınız ve en uygun bölmeyi seçiniz.

Aday bölme	Sol: n	Sol: Evet/Hayır	Sağ: n	Sağ: Evet/Hayır
A	5	4 / 1	7	2 / 5
B	6	5 / 1	6	1 / 5
C	4	3 / 1	8	3 / 5

```
Φ = 2 P_L P_R Σ_j | p(j|L) - p(j|R) |
```

İşlem ve cevap alanı

Soru 5 - CART Gini ile bölme seçimi (10 puan)

10 kredi başvurusunda toplam 6 Onay, 4 Red vardır. Üç aday ikili bölmenin sınıf sayıları aşağıda verilmiştir. Her alt grubun Gini değerini ve aday bölmenin ağırlıklı Gini değerini hesaplayınız. En küçük Gini'ye sahip niteliği seçiniz.

Aday nitelik	Sol grup: Onay/Red	Sağ grup: Onay/Red
Gelir (yüksek / düşük)	5 / 0	1 / 4
Yaş (genç / diğer)	2 / 2	4 / 2
Borç (düşük / yüksek)	5 / 1	1 / 3

```
Gini(B) = 1 - Σ_j p(j|B)^2 | Gini_bölme = (n_L/n)Gini_L + (n_R/n)Gini_R
```

İşlem ve cevap alanı

Soru 6 - Öklid, Manhattan ve Minkowski uzaklıkları (8 puan)

A = (2, -1, 4) ve B = (7, 3, 1) noktaları arasındaki (a) Öklid uzaklığını, (b) Manhattan uzaklığını ve (c) p = 3 için Minkowski uzaklığını hesaplayınız.

```
d_Öklid = √Σ(x_k-y_k)^2 | d_Manhattan = Σ|x_k-y_k| | d_Minkowski =
[Σ|x_k-y_k|^p]^(1/p)
```

İşlem ve cevap alanı

Soru 7 - Min-max normalleştirmeli k-NN (10 puan)

Aşağıdaki eğitim verisi için X1 aralığı [10,20], X2 aralığı [20,100] kabul edilecektir. Sınıfı bilinmeyen Q = (16,50) noktasını ve tüm eğitim kayıtlarını [0,1] aralığına min-max ile dönüştürünüz. Normalize uzayda Öklid uzaklıklarını hesaplayıp k = 3 için Q'nun sınıfını çoğunluk oylamasıyla belirleyiniz.

Kayıt	X1	X2	Sınıf
A	10	100	Evet
B	12	90	Evet
C	18	40	Hayır
D	20	20	Hayır
E	14	60	Evet

```
x' = (x-x_min)/(x_max-x_min)
```

İşlem ve cevap alanı

Soru 8 - Hiyerarşik kümeleme - tek bağlantı (10 puan)

Aşağıdaki beş nokta için Öklid uzaklık matrisini oluşturunuz. Birleştirici hiyerarşik kümelemeyi tek bağlantı (en yakın komşu) kuralıyla tek küme kalıncaya kadar sürdürünüz. Her birleşmede kümeleri ve birleşme uzaklığını yazınız. Eşit en küçük uzaklıklar aynı düzeyde ele alınabilir.

Nokta	P1	P2	P3	P4	P5
(x,y)	(1,1)	(2,2)	(5,4)	(6,5)	(9,1)

```
d_tek(A,B) = min{ d(a,b) : a∈A, b∈B }
```

İşlem ve cevap alanı

Soru 9 - Hiyerarşik kümeleme - tam bağlantı (8 puan)

Soru 8'deki aynı P1-P5 noktalarını kullanınız. Bu kez birleştirici hiyerarşik kümelemeyi tam bağlantı (en uzak komşu) kuralıyla tek küme kalıncaya kadar sürdürünüz. Her birleşmede kümeleri ve birleşme uzaklığını yazınız.

Nokta	P1	P2	P3	P4	P5
(x,y)	(1,1)	(2,2)	(5,4)	(6,5)	(9,1)

```
d_tam(A,B) = max{ d(a,b) : a∈A, b∈B }
```

İşlem ve cevap alanı

Soru 10 - K-Means iterasyonları ve kare-hata (16 puan)

Aşağıdaki altı nokta k = 2 ile kümelenecektir. Başlangıç merkezleri M1^(0) = A = (1,1) ve M2^(0) = C = (2,1)'dir. Her iterasyonda: (1) her noktanın iki merkeze Öklid uzaklığını hesaplayıp en yakın kümeye atayınız, (2) yeni merkezleri bulunuz, (3) yeni merkezlere göre toplam küme içi kare-hatayı E^2 hesaplayınız. Küme üyelikleri değişmeyene kadar sürdürünüz.

Nokta	A	B	C	D	E	F
(x,y)	(1,1)	(1,2)	(2,1)	(8,8)	(9,8)	(8,9)

```
M_k = (1/n_k)Σ x_i | E^2 = Σ_k Σ_(x_i∈C_k) ||x_i-M_k||^2
```

İterasyon tabloları, merkezler, kare-hata ve nihai cevap