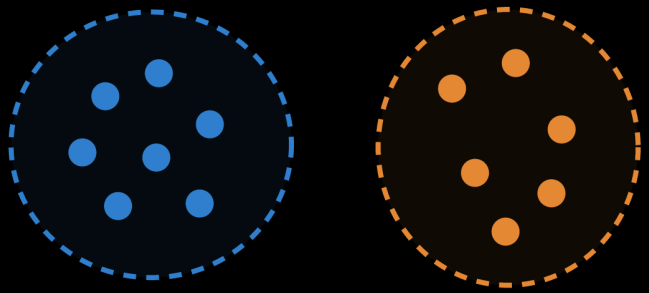
IV. Bölüm - Kümeleme (Clustring)

Kümeleme (Clustring)

* Kümeleme, bir veri kümesinde birbirine benzemeyen nesnelerin aynı grupta toplanmasıdır.

* Temel amaç:
  - Küme içi benzerliği artırmak: Aynı kümedeki nesnelerin birbirine yakın olması
  - Kümeler arası benzerliği artırmak: farklı kümelerdeki birbirine uzak olması

* Kümeleme, danışmansız öğrenme (unsupvised learning) kapsamındadır. Yani veriler önceden tanımlanmış sınıf etiketi bulunmaz.



Benzer nesneler aynı kümede toplanır.

Şekil 1. İki kümeli örnek veri dağılımı (temsili).

* Kümelemin kullanım alanları:
  - Örüntü tanıma
  - Görüntü işleme
  - Ekonomi
  - Aykırılık belirleme
  - Web (www)
  - Veri ön işleme
  - Veri azaltma

  } Kullanılır.

* İyi bir kümeleme algoritmasının özellikleri
  - Büyük veri kümeleriyle çalışabilmesi (ölçeklenebilirlik)
  - Sayısal ve kategorik verilere uygun yöntemlerle işleyebilmesi
  - farklı şekildeki kümelerin mümkün olduğunca az etkilenmesi
  - Gürültülü ve aykırı değerlerden mumkun olduğunca az etkilenmesi
  - Çok boyutlu veriler çalışabilmesi
  - Sonuçların anlaşılabilir ve yorumlanabilir olması

Benzerlik ve Uzaklık İlişkisi

$$d(i,j) = 1 - s(i,j)$$

Burda $s(i,j)$ iki nesne arasındaki benzerlik, $d(i,j)$ ise bunların farklılığını ifade eder.

"Örn: $s(A,B) = 0,85$

$d(A,B) = 1 - 0,85$

$= 0,15$

Kümeleme Algoritmalarında Uzaklık Ölçüleri

1. Öklid Uzaklığı

- İki nokta arası en kısa doğrusal ifadedir.

$$d(A,B) = \sqrt{\sum_{k=1}^{p} (a_k - b_k)^2}$$

- İki boyutlu için;

$$d(A,B) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Örnek: $A = (2,3)$ $B = (6,6)$

$$d(A,B) = \sqrt{(6-2)^2 + (6-3)^2} = 5$$

2. Manhattan Uzaklığı

- Koordinatların farklarının mutlak değerleri toplanır.

$$d(A,B) = \sum_{k=1}^{p} |a_k - b_k|$$

Örnek: $A = (2,3)$ $B = (6,6)$

$$d(A,B) = |6-2| + |6-3|$$

$$= 7$$

3. Minkowski Uzaklığı

- Öklid ve manhaten uzaklıklarını kapsayan fonksiyon

$$d(A,B) = \left(\sum_{k=1}^{p} |a_k - b_k|^m \right)^{1/m}$$

Örnek: $A = (2,3)$ $B = (6,6)$ $m = 3$

$$d(A,B) = (|6-2|^3 + |6-3|^3)^{1/3}$$

$$\cong 4,498$$

Hiyerarşik Kümeleme

* Hiyerarşik kümeleme, gözlemlerin aşamalı olarak birleştirilerek veya ayırarak iç içe girmiş kümelerden oluşan yöntemdir.

* Bu yaklaşımda:

1. Başlangıçta her gözlem tek başına bir kümedir.
2. Birbirine en yakın iki küme bulunur.
3. Bu iki küme birleştirilir.
4. Kümeler arası uzaklık güncelenir.
5. İstenen küme sayısı veya tek bir kümeye ulaşana kadar devam eder.

En yakın komşu Algoritması

* İki küme arasındaki uzaklık, bu kümelerde bulunan birbirine yakın iki noktanın uzaklığı olarak bakılır.

$$D(A,B) = \min_{a \in A \text{ ve } b \in B} d(a,b)$$

* Örneğin; A kümesi iki, B kümesi bir nokta:

$A = \{x_1, x_2\}$ $B = \{x_3\}$

$d(x_1, x_3) = 2,83$

$d(x_2, x_3) = 3,16$

Bu durumda;

$D(A,B) = \min(2,86 , 3,16)$

$= 2,86$

Örnek: Aşağıda tabloda verilen beş gözlem a eğeri, en yakın komşu algoritması ile kümelenmek isteniyor.

Gözlem	x_1	x_2
1	4	2
2	6	4
3	5	1
4	10	6
5	11	8

1. Adım : Gözlemler arası Öklid uzaklığını hesapla

$d(1,2) = \sqrt{(6-4)^2 + (4-2)^2} = 2,83$

$d(1,3) = \sqrt{(5-4)^2 + (4-2)} = 1,41$

$d(1,4) = \sqrt{(5-4)^2 + (1-2)^2} = 7,21$

$d(1,5) = \sqrt{(11-4)^2 + (8+2)^2} = 9,22$

2. Gözlem:

$d(2,3) = \sqrt{(5-6)^2 + (1-4)^2} = 3,16$

$d(2,4) = \sqrt{(10-6)^2 + (6-4)^2} = 4,47$

$d(2,5) = \sqrt{(11-6)^2 + (8-4} = 6,40$

3. Gözlem:

$d(3,4) = \sqrt{(10-5)^2 + (6-1)^2} = 7,07$

$d(3,5) = \sqrt{(11-5)^2 + (8-1)^2} = 9,22$

4. Gözlem:

$d(4,5) = \sqrt{(11-10)^2 + (8-6)^2} = 2,24$

Tam uzaklık matrisi:

	1	2	3	4	5
1	0	2,83	1,41	7,21	9,22
2	2,83	0	3,16	4,47	6,40
3	1,41	3,16	0	7,07	9,22
4	7,21	4,47	7,07	0	2,24
5	9,22	6,40	9,22	2,24	0

Uzaklık matrisi simetriktir:

$$d(i,j) = d(j,i)$$

Bir gözlemin kendisine uzaklığı ise sıfırdır.

2. Adım: En Küçük Uzaklığa Sahip Noktaları Birleştirme

- Matristeki en küçük değer:

$$\min d(i,j) = 1,41$$

Bu uzaklık 1 ve 3 numaralı gözlemdedir.

$$C_1 = \{1,3\}$$

Yeni küme:

$\{1,3\}, \{2\}, \{3\}, \{4\}, \{5\}$

$D(\{1,3\},\{2\}) = \min(2,83, 3,16) = 2,83$

$D(\{1,3\},\{4\}) = \min(7.21, 7.07) = 7.07$

$D(\{1,3\},\{5\}) = \min(9.22, 9.22) = 9.22$

Güncellenen matris

Küme	(1,3)	2	4	5
(1,3)	0	2,83	7,07	9,22
2	2,83	0	4,47	6,40
4	7,07	4,47	0	2,24
5	9,22	6,40	2,24	0

* İşlemler tek matrisle birleşene kadar devam eder

En Uzak Komşu Algoritması

* en yakın komşu algoritması ile aynı birleşim kuralını kullanır. Fakat iki küme arasındaki en büyük nokta seçilir.

$$D(A,B) = \max d(a,b)$$

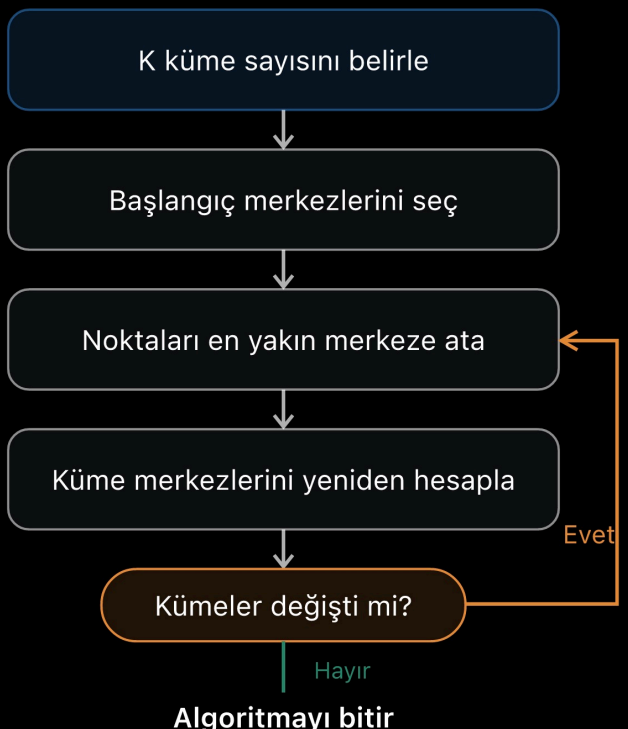
* Önceki örnekte:

$$d(\{1,3\}, 2) = \max(2,83, 3.16) = 3.16$$

K - Ortalamalar Algoritması (K-means)

* K-means, hiyerarşik olmayan kümeleme yöntemidir.
* Amaç, N adet gözlemi önceden belirlenmiş K adet kümeye ayırarak gözlemlerin kendi küme merkezine olan kareli uzaklıkları toplamı mümkün olduğunca küçülmeli

* K-means'in temel adımları
1. Küme sayısını (K) belirle
2. Başlangıç küme merkezi belirle
3. Her gözlem en yakın merkeze atılır.
4. Kümelerin yeni merkezleri hesaplanır.
5. Küme atamaları değişmeyince dur.



Şekil 5. K-Means algoritmasının iteratif çalışma süreci.

Küme merkezinin hesaplanması

- Bir kümedeki noktaların koordinatların aritmetik ortalamasıdır.

$$M_K = \frac{1}{n} \sum_{i=1}^{n} x_i$$

Örneğin; $C_1 = \{(2,4), (4,6), (6,8)\}$

$$M_K = \left(\frac{2+4+6}{3}, \frac{4+6+8}{3} \right) = (4, 6)$$

Küme içi Karesel Hata (SSE)

$$SSE = \sum_{i=1}^{K} \sum_{x_i \in C} \| x_i - M_K \|^2$$

- Burda:
  - K = küme sayısı
  - C_K = K. küme
  - M_K = K. küme merkezi
  - x_i = Kümedeki gözlem
  - $\| x_i - M_K \|^2$ = Merkeze olan öklid uzaklığı karesi

Örnek 2.

- Aşağıdaki gözlem değerleri k-ortalamalar yöntemi ile kümelenmek isteniyor.

Gözlemler	Değişken1	Değişken2
X_1	4	2
X_2	6	4
X_3	5	1
X_4	10	6
X_5	11	8

- Kümelerin sayısı başlangıçta k=2 kabul edilir. Rasgele iki küme belirlenir.

$$C_1 = \{X_1, X_2, X_4\}$$
$$C_2 = \{X_3, X_5\}$$

1. Adım = Küme merkezleri hesapla

- C_1 için;

$$M_1 = \left(\frac{4+6+10}{3}, \frac{2+4+6}{3} \right) = (6{,}67, 4)$$

- C_2 için;

$$M_2 = \left(\frac{5+11}{2}, \frac{8+1}{2} \right) = (8, 4{,}5)$$

2. lik SSE hesaplanması

$$SSE_1 = [(4-6{,}67)^2 + (2-4)^2] + [(6-6{,}67)^2 + (4-4)^2] + [(10-6{,}67)^2 + (6-4)^2]$$
$$\approx 26{,}67$$

$$SSE_2 = [(5-8)^2 + (1-4{,}5)^2] + [(11-8)^2 + (8-4{,}5)^2] = 42{,}50$$

3. Adım = Gözlemleri en yakın merkeze Atama

- Her bir değer için seçilen iki merkeze uzaklıkları hesaplanır.

Örneğin $X_1 = (4, 2)$ için;

$$d(X_1, M_1) = \sqrt{(4-6{,}67)^2 + (2-4)^2} \approx 3{,}33$$

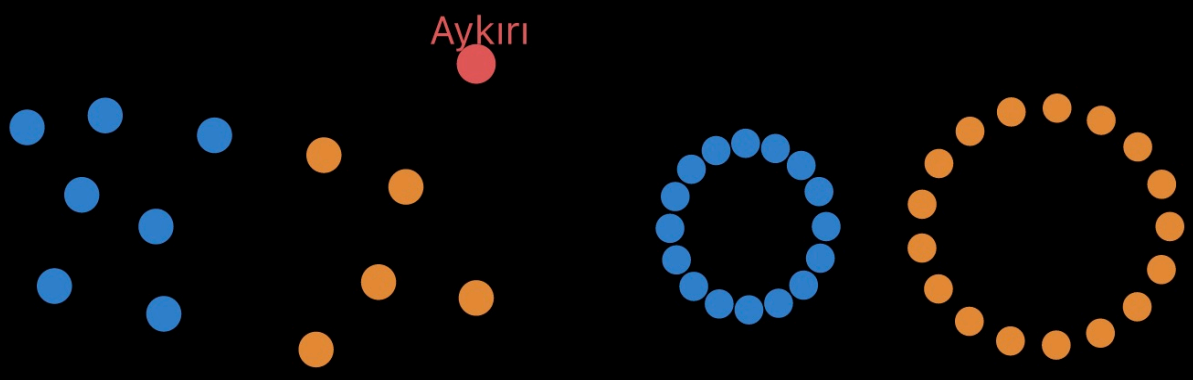
$$d(X_2, M_2) = \sqrt{(4-8)^2 + (2-4{,}5)^2} \approx 4{,}72$$

4. Adım: Küme atamaları değişmeyince dur

K-means avantajları

Avantajlar	Dezavantajlar
Uygulanması kolaydır.	Küme sayısı K önceden belirlenmelidir.
Büyük veri kümelerinde verimli olabilir.	Başlangıç merkezlerinden etkilenebilir.
Matematiksel olarak anlaşılması kolaydır.	Aykırı değerlere duyarlıdır.
Merkezler kullanılarak veriler özetlenebilir.	Küresel olmayan kümelerde başarısız olabilir.
Tekrarlı biçimde iyileştirme yapar.	Farklı yoğunluk ve boyuttaki kümelerde sorun yaşayabilir.

9.1. K-Means hangi durumlarda başarısız olabilir?



Aykırı değerler
Merkezleri değiştirebilir.

Farklı büyüklükler
Kümeleri yanlış ayırabilir.

Veri kümelerinin şekilleri karmaşık olduğunda veya aykırı değerler bulunduğunda farklı kümeleme yöntemleri tercih edilebilir.